Inferencia de propiedades físicas de galaxias a partir de imágenes multibanda

Aprendizaje multitarea, adaptación de modelos preentrenados y ensambles heterogéneos

Luz Copelia Minutti Pérez
A01796921

Erick Alberto Bustos Cruz
A01378966

Maestría en Inteligencia Artificial Aplicada · Proyecto Integrador · Equipo 24
Instituto Tecnológico y de Estudios Superiores de Monterrey
En colaboración con el Instituto de Astronomía de la UNAM

Asesores: Dr. Iván Reyes Amezcua (ITESM)
Dr. Héctor Hernández Toledo y Dr. José Antonio Vázquez Mata (IA-UNAM)

Noviembre de 2026

Resumen

En este trabajo se estiman la masa estelar, la tasa de formación estelar (SFR) y el índice D4000 de galaxias mediante imágenes multibanda de DESI Legacy Imaging Surveys y redshift. El estudio comprende 9,299 galaxias con etiquetas de MaNGA/Pipe3D y plantea la estimación conjunta de estas propiedades como un problema de regresión multitarea. El desarrollo, organizado con CRISP-ML(Q), abarcó la preparación de datos, la ingeniería de características, la reproducción de Katachi como línea base, la comparación de seis modelos candidatos y la construcción de ensambles. Las pruebas de ablación y la evaluación con tres semillas permitieron examinar el efecto de las entradas, las representaciones y las configuraciones de entrenamiento. El modelo seleccionado combina DINOv3 con LoRA, ConvNeXt-Tiny y EfficientNet-B3 mediante una mezcla convexa que promedia tres semillas por arquitectura y asigna pesos por propiedad. En 917 galaxias de prueba obtuvo RMSE de 0.0969 dex en masa, 0.5575 dex en SFR y 0.0676 en D4000. El error normalizado conjunto disminuyó 37 % frente a la línea base del proyecto, y el RMSE de masa quedó por debajo de la meta de 0.15 dex. Los resultados muestran que incorporar información de distancia, adaptar las representaciones preentrenadas y combinar arquitecturas complementarias mejora la estimación. A partir de estos hallazgos, se propone procesar catálogos por lotes, con versiones registradas del modelo y del preprocesamiento, controles de entrada y seguimiento del desempeño.

Palabras clave: visión computacional; regresión multitarea; aprendizaje por transferencia; LoRA; ensambles; CRISP-ML(Q).

1. Contexto institucional y problema

1.1. Colaboración académica y objetivo del estudio

Este proyecto se desarrolló con la asesoría científica de los doctores Héctor Hernández Toledo y José Antonio Vázquez Mata, del Instituto de Astronomía de la Universidad Nacional Autónoma de México, y la asesoría académica del Dr. Iván Reyes Amezcua, del Instituto Tecnológico y de Estudios Superiores de Monterrey. La colaboración se centra en la estimación de propiedades físicas de galaxias a partir de imágenes multibanda, un problema relevante para el análisis de grandes catálogos y el estudio de las poblaciones galácticas.

Las imágenes registran el brillo, el color y la estructura espacial de las galaxias, mientras que el análisis espectroscópico proporciona estimaciones de sus propiedades físicas que pueden utilizarse como etiquetas de entrenamiento. El crecimiento de los levantamientos de imágenes, entre ellos el del Observatorio Vera C. Rubin, plantea la necesidad de desarrollar métodos que permitan caracterizar estas poblaciones de manera sistemática y a gran escala [1].

En este contexto, el objetivo del proyecto es construir y validar un modelo de regresión para estimar la masa estelar ($\log M_\star$), la tasa de formación estelar ($\log \mathrm{SFR}$) y el índice D4000 a partir de imágenes de DESI Legacy Imaging Surveys. La masa describe el contenido estelar de la galaxia; la SFR, su actividad de formación de estrellas; y D4000, una característica espectral asociada con su población estelar. El modelo final incorpora además el redshift, cuya información de distancia ayuda a interpretar el brillo aparente.

El método está orientado a la exploración de catálogos, la comparación de poblaciones y la selección de objetos para estudios posteriores. Su desarrollo requiere resolver tres dificultades relacionadas: aprender a partir de una muestra etiquetada moderada, integrar imágenes con una variable tabular y estimar simultáneamente propiedades expresadas en escalas distintas. La evaluación considera el error de predicción, la estabilidad del entrenamiento y el costo de aplicar el modelo a nuevos objetos.

1.2. Antecedentes y enfoque del estudio

El principal antecedente es Katachi [2], cuya arquitectura encadena tres redes ResNet50. La primera predice la masa; la segunda incorpora esa estimación para inferir la SFR; y la tercera utiliza las estimaciones anteriores para obtener D4000. Su reproducción con imágenes DESI proporcionó una línea base con la cual comparar los modelos desarrollados.

A partir de esa referencia, se exploró una arquitectura multitarea con un extractor visual compartido y tres cabezas de regresión. La incorporación posterior del redshift permitió combinar las características de la imagen con información de distancia antes de calcular las salidas. Se compararon redes convolucionales, un transformador de visión y regresores clásicos sobre características visuales; después se evaluó la combinación de semillas y arquitecturas mediante ensambles.

La comparación se realizó con un protocolo común de preparación y evaluación. Las pruebas de ablación permitieron relacionar los cambios en las entradas y el entrenamiento con las variaciones del error, mientras que la selección final consideró el desempeño y el número de redes necesarias

para estimar las propiedades de cada galaxia. De este modo, la elección del ensamble se apoyó en los resultados de los experimentos y en su costo computacional.

1.3. Metodología de trabajo y criterios de éxito

El trabajo se organizó con CRISP-ML(Q), que integra el aseguramiento de calidad a lo largo del desarrollo y la operación de modelos [3]. La caracterización de los datos precedió a la preparación de imágenes y la construcción de referencias; los resultados de estas etapas orientaron la comparación de modelos y el diseño de los ensambles. El Anexo A resume esta secuencia y las decisiones adoptadas en cada etapa.

Los criterios de éxito se establecieron durante la construcción de la línea base. Se evaluó la viabilidad frente a un predictor constante y se adoptó Katachi como referencia, con márgenes de no inferioridad de 0.02 dex para masa y SFR y de 0.01 para D4000. Para masa se fijó, además, una meta de RMSE de 0.15 dex, considerando la dispersión entre métodos de estimación discutida en la literatura [4]. La comparación se complementó con el análisis de estabilidad entre semillas, generalización y tiempo de inferencia.

2. Datos y preparación

2.1. Conjunto de datos y formulación supervisada

Las entradas visuales proceden de DESI Legacy Imaging Surveys, en las bandas g, r y z [5]. Las etiquetas provienen del análisis Pipe3D de MaNGA [6, 7]. El identificador `mangaid` enlaza imágenes, variables y predicciones. La Tabla 1 resume el papel de cada componente.

Componente	Representación	Función
Imagen multibanda	Recorte en g, r, z	Aprender color, brillo y estructura espacial.
Redshift	Escalar estandarizado	Aportar contexto de distancia al vector visual.
Masa y SFR	`log_Mass`, `log_SFR_Ha`	Objetivos de regresión en logaritmo decimal.
D4000	`D4000_Re_fit1`	Tercer objetivo de regresión, adimensional.
Identificador y partición	`mangaid`, entrenamiento, validación, prueba	Alinear observaciones y mantener el protocolo experimental.
Fotometría NSA	Color $g - i$ y magnitud absoluta M_i	Construir una referencia de baja complejidad.

Tabla 1: Datos utilizados y función en el modelo.
Fuente: Catálogo maestro y cuadernos del proyecto.

Partimos de 9,661 galaxias y seleccionamos observaciones con `QCFLAG=0`. Tras los controles de integridad de las entradas, la muestra de modelado quedó en 9,299 objetos: 7,121 de entrenamiento,

1,261 de validación y 917 de prueba. Los parámetros dependientes de los datos se calcularon exclusivamente en entrenamiento. Esta separación comprende escalas de imagen, medias y desviaciones de las etiquetas, e información necesaria para transformar el redshift. El Anexo B reúne los conteos y las transformaciones.

Para cada galaxia i, el sistema aprende la relación $f_\theta(X_i, z_i) = \hat{\mathbf{y}}_i$, donde X_i es la imagen, z_i el redshift y $\mathbf{y}_i = (\log M_{\star,i}, \log \mathrm{SFR}_i, D4000_i)$. Masa y SFR se expresan en dex; D4000 es adimensional. La estandarización de las salidas facilita el entrenamiento conjunto y se invierte al reportar las predicciones.

2.2. Preparación de las imágenes

Se utilizaron recortes centrales de 300×300 píxeles a la escala nativa de 0.262 segundos de arco por píxel. El análisis de tamaño angular mostró que el campo resultante, de 78.6 segundos de arco por lado, contiene por completo al 97.8 % de las galaxias. Este tamaño permite reducir los requerimientos de memoria y cómputo sin interpolar los píxeles del recorte.

La normalización se eligió procurando conservar las diferencias de brillo entre galaxias. Al escalar cada imagen de forma independiente, la correlación de Spearman entre la señal evaluada y la masa descendió de 0.55 a 0.02; por ello se adoptaron escalas globales por banda, calculadas con el conjunto de entrenamiento. La transformación asinh comprime el rango dinámico y permite representar regiones brillantes y señal tenue, mientras que la estandarización posterior mantiene escalas numéricas comparables.

ConvNeXt y EfficientNet reciben las bandas transformadas y estandarizadas. Para DINOv3 se emplea una composición de Lupton [8] con un recorte de 288×288 píxeles, compatible con sus parches de 16×16. La Figura 1 presenta ejemplos de las imágenes utilizadas.

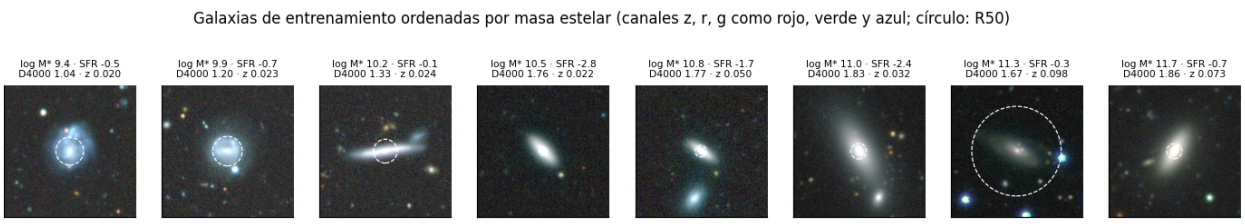


Figura 1: Representaciones visuales de las galaxias empleadas en el proyecto. El procesamiento conserva información multibanda y concentra la entrada en la región de interés. Fuente: cuadernos del proyecto.

Durante el entrenamiento se aplicaron rotaciones de 90° y reflejos, ya que las propiedades globales que se desea estimar no cambian con la orientación de la galaxia. Estas transformaciones aumentan la variedad de ejemplos sin introducir los píxeles de relleno que producirían los giros arbitrarios. En inferencia se promediaron las predicciones de las ocho simetrías mediante *test-time augmentation* (TTA).

2.3. Ingeniería de características

Se construyeron 51 características de color, tamaño, concentración, brillo superficial, morfología y condiciones de observación. Su selección mediante filtros y validación cruzada redujo el conjunto a 24 variables. La comparación con los modelos de imagen permitió examinar qué información explicaba las diferencias de desempeño.

El efecto más marcado se observó en la información de distancia. Un modelo de *gradient boosting* sobre las características seleccionadas alcanzó un RMSE de masa de 0.123 dex, frente a 0.224 dex de la referencia de imagen de esa etapa. Al retirar las variables relacionadas con la distancia, el error aumentó a 0.329 dex. Como las redes conservaban la ventaja en SFR y D4000, se decidió mantener el aprendizaje visual e incorporar el redshift como entrada adicional.

El análisis de las etiquetas mostró una proporción importante de galaxias con baja formación estelar y dos poblaciones en la distribución de D4000 (Figura 2). Para examinar el comportamiento del modelo en estos grupos, las métricas globales se complementaron con residuos por intervalo de propiedad y redshift.

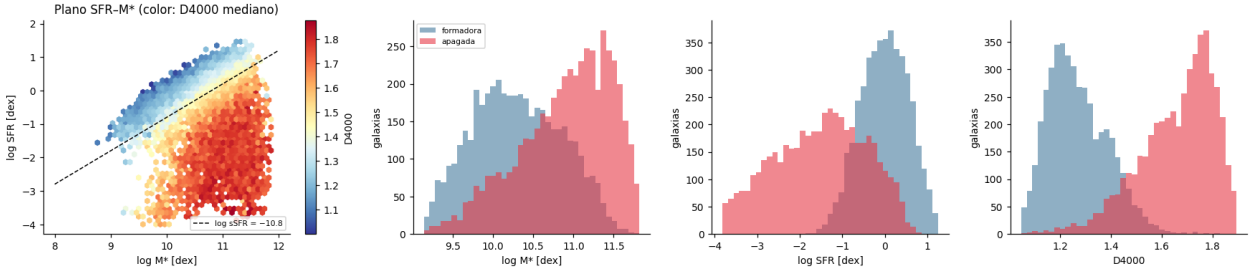


Figura 2: Distribución de las etiquetas de entrenamiento. Izquierda: relación SFR–masa, coloreada por D4000. Derecha: distribuciones por población. La heterogeneidad de los objetivos motivó evaluar el error global y por grupos. Fuente: cuadernos del proyecto.

3. Metodología y modelos

3.1. Protocolo experimental y métrica conjunta

Todos los modelos se evaluaron con particiones y criterios comunes, manteniendo la correspondencia de las observaciones mediante el identificador de cada galaxia. Los parámetros se ajustaron en entrenamiento; las variantes y los hiperparámetros se seleccionaron en validación; y el conjunto de prueba se evaluó después de registrar el modelo final. Esta separación reduce el riesgo de sobreajuste durante la selección [9]. Cada red se entrenó con las semillas 42, 7 y 2026 para examinar la variación entre corridas.

Para cada propiedad k se reportan RMSE, MAE, R^2, sesgo medio y dispersión robusta. El RMSE penaliza especialmente errores grandes; el MAE resume el error absoluto medio; el sesgo muestra

desplazamientos sistemáticos. La comparación conjunta utiliza

$$C = \frac{1}{3}\sum_{k=1}^{3}\frac{\mathrm{RMSE}_k^2}{\sigma_{k,\mathrm{ent}}^2}, \qquad \mathrm{RMSE}_k = \sqrt{\frac{1}{N}\sum_{i=1}^{N}(\hat{y}_{ik} - y_{ik})^2}. \tag{1}$$

Las desviaciones de entrenamiento son 0.6467, 1.1613 y 0.2427 para masa, SFR y D4000, respectivamente. Al dividir cada MSE por la varianza correspondiente, los errores de las tres propiedades pueden combinarse sin que sus unidades determinen el peso relativo. Un valor menor de C indica mejor desempeño conjunto; las métricas individuales se reportan en las unidades originales.

3.2. Líneas base y alternativas de modelado

Se utilizaron tres referencias de complejidad creciente. El predictor de la media estima el desempeño que se obtiene sin información individual de las galaxias. El baseline fotométrico B1 emplea $g - i$ y M_i: para masa ajusta una relación basada en Taylor et al. [10], y para SFR y D4000 utiliza Random Forest. B2 reproduce Katachi con redes ResNet50 preentrenadas y ajustadas a imágenes DESI; en prueba obtuvo RMSE de 0.223 dex en masa, 0.653 dex en SFR y 0.073 en D4000.

A continuación se compararon ResNet50 multitarea, SVR, ConvNeXt-Tiny, DINOv3 con LoRA, Ridge y KNN. Los regresores clásicos permitieron evaluar el uso de características extraídas con una red preentrenada y fija; las CNN, el beneficio de ajustar el extractor a las imágenes del proyecto. Con DINOv3 se examinó una representación aprendida de forma autosupervisada y adaptada mediante un conjunto reducido de parámetros entrenables. La Tabla 2 resume el fundamento de estas alternativas.

Modelo	Fundamento	Pregunta que responde
ResNet50 multitarea	Conexiones residuales y representación compartida [11, 12].	¿Qué aportan compartir tareas, cambiar la entrada y usar una pérdida robusta?
ConvNeXt-Tiny	CNN moderna con bloques y decisiones de entrenamiento actualizados [13].	¿Mejora una representación convolucional adaptada al dominio?
DINOv3 + LoRA	Representaciones autosupervisadas y actualización de bajo rango [14, 15].	¿Cómo adaptar un modelo de gran capacidad con una muestra moderada?
SVR, Ridge y KNN	Regresión no lineal, lineal regularizada y basada en vecinos.	¿Cuánto se obtiene con características visuales fijas y un estimador sencillo?
EfficientNet-B3	Escalamiento coordinado de profundidad, ancho y resolución [16].	¿Aporta una CNN eficiente diversidad y buen costo de inferencia al ensamble?

Tabla 2: Estrategias de modelado y función en la comparación experimental.
Fuente: Diseño experimental del equipo y literatura citada. EfficientNet se incorporó en la etapa de ensambles.

3.3. Aprendizaje multitarea y fusión de entradas

La arquitectura multitarea aprende un vector visual compartido $\mathbf{h} = f_\theta(X)$. Después concatena el redshift estandarizado $\tilde{z}$ y emplea una cabeza por objetivo:

$$\mathbf{u} = [\mathbf{h}; \tilde{z}], \qquad \hat{y}_k = \mu_{k,\text{ent}} + \sigma_{k,\text{ent}}\, g_{\phi_k}(\mathbf{u}), \quad k \in \{M, S, D\}. \tag{2}$$

El extractor compartido aprende patrones visuales relacionados con las tres propiedades, mientras las cabezas independientes modelan la relación específica con cada objetivo [12]. El redshift se concatena al vector de características, de modo que la información de distancia se integra después del procesamiento de la imagen. Las entradas y las salidas se estandarizan para mantener escalas numéricas comparables durante la optimización.

En ResNet50 se evaluaron siete variantes que contrastan redes independientes y extractor compartido, imágenes RGB y bandas GRZ, la presencia de redshift y las pérdidas MSE y Huber. El criterio medio descendió de 0.1838 a 0.1269, con la mayor mejora asociada a la incorporación de redshift. La variante E reunió el extractor compartido, la representación GRZ, el redshift y la pérdida Huber. El Anexo C presenta las configuraciones y sus resultados.

La pérdida Huber combina un término cuadrático para residuos pequeños con un crecimiento lineal para los grandes [17]:

$$\mathcal{L}_\delta(e) = \begin{cases} \frac{1}{2}e^2, & |e| \le \delta, \\ \delta(|e| - \frac{1}{2}\delta), & |e| > \delta. \end{cases} \tag{3}$$

En las configuraciones con Huber se empleó $\delta = 1$ sobre los objetivos estandarizados. El crecimiento lineal para residuos grandes modera su influencia durante el ajuste, a la vez que el término cuadrático mantiene la sensibilidad a errores pequeños. La comparación experimental seleccionó Huber en ResNet50 E, DINOv3 y EfficientNet; ConvNeXt mantuvo MSE.

3.4. Transferencia, adaptación eficiente y optimización

El preentrenamiento proporciona una representación inicial cuando el número de imágenes etiquetadas es limitado. Dado que las imágenes astronómicas difieren de las fotografías utilizadas para entrenar esos extractores, se compararon versiones congeladas y ajustadas al dominio.

En la etapa de solo imagen, DINOv3 obtuvo un criterio de 0.259 con el extractor congelado y de 0.152 tras la adaptación con LoRA. Este método conserva los pesos base y expresa la actualización de matrices seleccionadas como $\Delta W = (\alpha/r)BA$, donde r es un rango menor que las dimensiones de la matriz original [15]. Se eligió rango 32 y se ajustaron aproximadamente 5.1 millones de parámetros de un modelo de 308 millones, alrededor de 1.7 %. La reducción de parámetros entrenables facilita el ajuste, aunque la inferencia sigue requiriendo ejecutar la red completa.

La optimización se realizó con Optuna [18] y consideró tasas de aprendizaje, regularización y configuración de entrenamiento. En ConvNeXt, 30 pruebas redujeron el criterio de 0.177 a 0.163. Para DINOv3 se exploraron representaciones congeladas, configuraciones de la cabeza y 16 pruebas de ajuste fino; EfficientNet-B3 se ajustó con 12 pruebas. La Tabla 3 resume las búsquedas y el Anexo D reúne las configuraciones finales.

Modelo	Exploración	Resultado de desarrollo
ResNet50	Siete variantes A–G y tres semillas por variante.	C: 0.1838 → 0.1269.
ConvNeXt	30 pruebas sobre nueve hiperparámetros.	C: 0.177 → 0.163.
DINOv3	48 representaciones congeladas, 40 pruebas de la cabeza y 16 de ajuste fino.	C: 0.259 → 0.152; LoRA de rango 32.
EfficientNet-B3	12 pruebas con poda de configuraciones poco prometedoras.	Configuración con Huber; C medio de 0.1287 con redshift, antes de TTA.

Tabla 3: Búsquedas de hiperparámetros y resultados de validación.
Fuente: Cuadernos de modelos candidatos y modelos base. Cada fila resume la optimización de esa arquitectura.

En ConvNeXt, el decaimiento de la tasa de aprendizaje por capa fue el hiperparámetro más influyente de la búsqueda. Las mejores configuraciones permitieron adaptar el extractor completo. Para evaluar la incorporación de redshift en ConvNeXt y DINOv3, se conservaron los hiperparámetros previamente seleccionados y se modificó únicamente esa entrada.

3.5. Diseño del ensamble: estabilidad y complementariedad

Los ensambles se construyeron en dos niveles. Primero se promediaron tres semillas de una misma arquitectura para reducir la variación entre entrenamientos. Después se combinaron arquitecturas cuyos errores fueran parcialmente distintos. Bajo pérdida cuadrática, la descomposición de ambigüedad establece que el error de un promedio ponderado es igual al error medio ponderado de sus miembros menos su desacuerdo [19]; por ello se buscó combinar modelos con buen desempeño y errores complementarios.

El ensamble final reúne DINOv3 con LoRA, ConvNeXt-Tiny y EfficientNet-B3, todos con imagen y redshift como entradas. En cada arquitectura se promedian tres semillas y las predicciones de ocho simetrías de la imagen. Agrupar primero las semillas permite ajustar el combinador sobre tres predicciones por propiedad. La Figura 3 muestra la arquitectura y la Tabla 4, los pesos obtenidos.

La mezcla convexa estima cada propiedad k mediante

$$\hat{y}_k = \sum_{m=1}^{3} w_{mk}\bar{y}_{mk}, \qquad w_{mk} \geq 0, \qquad \sum_{m=1}^{3} w_{mk} = 1, \tag{4}$$

donde $\bar{y}_{mk}$ es el promedio de las semillas de la arquitectura m. Los pesos minimizan el MSE normalizado más la penalización $\lambda \sum_m (w_{mk} - 1/3)^2$. Las restricciones mantienen la predicción dentro del intervalo de sus miembros y la penalización evita alejarse innecesariamente del promedio uniforme. Permitir pesos por propiedad responde a que cada arquitectura puede aportar de manera diferente a las tres tareas.

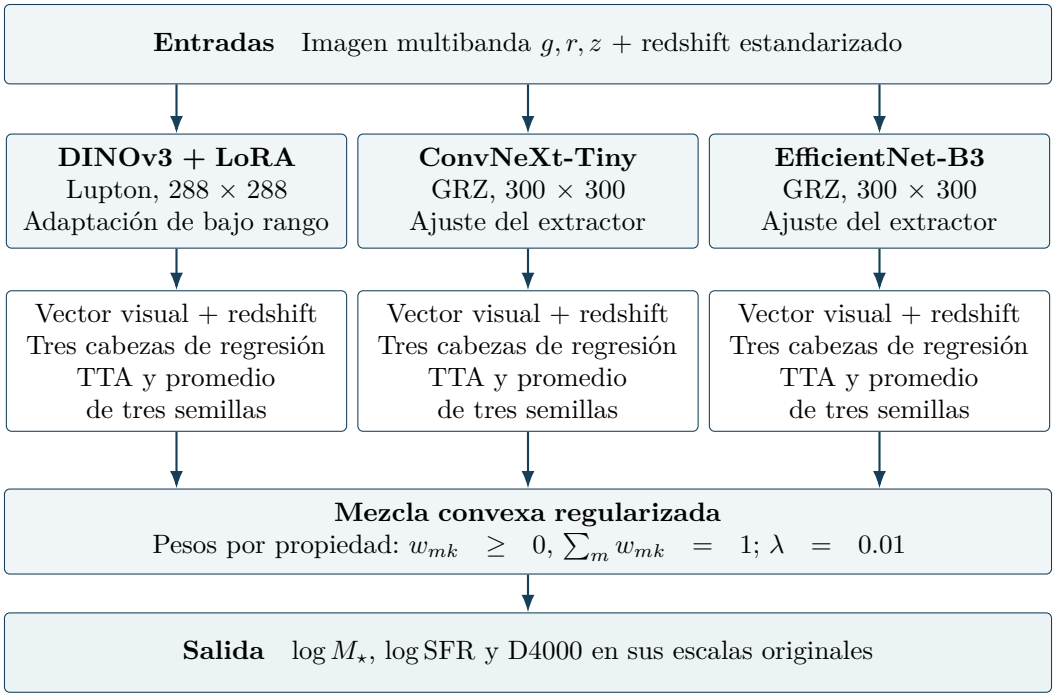


Figura 3: Arquitectura del modelo final. Cada rama contiene tres redes entrenadas con semillas distintas. El redshift se concatena al vector visual de cada red antes de las cabezas. Las predicciones se promedian por simetría y semilla, y se combinan por propiedad. Elaboración propia.

Arquitectura	Masa	SFR	D4000
DINOv3 con LoRA	0.28	0.49	0.39
ConvNeXt-Tiny	0.36	0.35	0.31
EfficientNet-B3	0.36	0.16	0.30

Tabla 4: Pesos de la mezcla convexa seleccionada, redondeados a dos decimales.
Fuente: Cuaderno de ensambles heterogéneos; $\lambda = 0.01$.

También se construyó un meta-aprendiz, siguiendo la idea de combinar predictores mediante un segundo nivel de aprendizaje [20, 21]. Este recibió las predicciones de los miembros y exploró correcciones del promedio con regresión lineal positiva, red elástica, Ridge y *gradient boosting*. La hipótesis fue que un combinador más flexible podría corregir patrones residuales comunes.

Los combinadores se ajustaron sobre la reserva de validación mediante cinco pliegues externos, cuatro internos y tres repeticiones. Los pliegues internos seleccionaron la configuración; los externos estimaron su error en galaxias no utilizadas para ajustar ese combinador. Las redes base permanecieron fijas durante este procedimiento. Una vez elegida la configuración, el combinador se ajustó con toda la validación y se aplicó a prueba.

3.6. Selección del modelo final

La selección siguió la regla de un error estándar: entre los modelos cuyo desempeño difiere del mejor en menos de ese margen, se elige el más simple [22]. La complejidad se midió como el número de redes que deben ejecutarse por galaxia. Puesto que todos los modelos predicen los mismos objetos, el error estándar se calculó sobre la diferencia pareada de sus pérdidas.

La mezcla convexa obtuvo el menor criterio de validación, 0.1037, y ninguna de las otras alternativas de la comparación final quedó dentro del margen de un error estándar. Se seleccionó, por tanto, antes de evaluar la prueba, y se registraron su configuración y las huellas de las predicciones. La Tabla 5 presenta los valores de desempeño, costo y diferencia pareada.

Modelo	C	Redes	ms/galaxia	Diferencia (EE)
Mezcla convexa	**0.1037**	9	10.62	–
Meta-aprendiz	0.1046	9	10.62	0.0009 (0.0003)
Homogéneo DINOv3	0.1081	3	8.08	0.0044 (0.0015)
DINOv3 individual	0.1092	1	2.69	0.0056 (0.0017)
Homogéneo ConvNeXt	0.1102	3	1.35	0.0065 (0.0015)
Homogéneo EfficientNet	0.1165	3	1.19	0.0128 (0.0023)

Tabla 5: Selección en validación: desempeño conjunto y costo de inferencia.
Fuente: Avance 5. EE: error estándar de la diferencia con el mejor. Tiempos en NVIDIA A100, sin TTA; las métricas incluyen TTA.

El promedio uniforme de las arquitecturas alcanzó un criterio de 0.1038, muy cercano al 0.1037 de la mezcla convexa. Esta proximidad indica que la mejora proviene principalmente de combinar los miembros. Los pesos por propiedad permiten ajustar la participación de cada arquitectura, pero la mayor flexibilidad del meta-aprendiz no produjo una mejora adicional. La Tabla 6 resume las decisiones adoptadas y los resultados que las respaldan.

Decisión	Fundamento	Evidencia que la respalda
Escalas globales por banda	Conservar información entre objetos y estabilizar magnitudes numéricas.	La normalización individual redujo la correlación brillo–masa de 0.55 a 0.02.
Imagen + redshift	Integrar información complementaria mediante fusión de características.	Las ablaciones redujeron aproximadamente a la mitad el RMSE de masa.
Adaptar el preentrenamiento	Ajustar la representación al dominio con una muestra moderada.	DINOv3 pasó de 0.259 congelado a 0.152 con LoRA.
Promediar semillas	Reducir variación debida a la inicialización y al entrenamiento.	ConvNeXt pasó de 0.1170 individual a 0.1102 como homogéneo.
Combinar arquitecturas	Aprovechar errores parcialmente complementarios.	Mezcla: 0.1037; mejor homogéneo: 0.1081 en validación.
Regularizar la combinación	Limitar la sensibilidad de los pesos a la muestra de ajuste.	$\lambda = 0.01$ y variación de 0.0002 entre repeticiones.
Seleccionar antes de prueba	Separar desarrollo y evaluación final.	Registro de configuración, predicciones y regla de selección.

Tabla 6: Relación entre decisión técnica, fundamento y evidencia del proyecto.
Fuente: Síntesis de los experimentos del equipo.

4. Resultados y validación

4.1. Desempeño del modelo final

En las 917 galaxias de prueba, la mezcla convexa obtuvo un criterio de 0.1102 y un RMSE de masa de 0.0969 dex, inferior a la meta de 0.15 dex. La Tabla 7 reúne las métricas por propiedad y la Figura 4 compara las predicciones con las etiquetas. Los valores de R^2 corresponden a 97.6 % de la variación de masa, 78.9 % de SFR y 92.0 % de D4000 en esta muestra.

Propiedad	RMSE	MAE	R^2
Masa estelar [dex]	**0.0969**	0.0728	0.9760
SFR [dex]	**0.5575**	0.3544	0.7892
D4000	**0.0676**	0.0482	0.9201

Tabla 7: Desempeño del modelo final en el conjunto de prueba.
Fuente: Avance 5; 917 galaxias. Criterio conjunto: 0.1102.

Frente a B2, el criterio disminuyó de 0.175 a 0.1102, una reducción de aproximadamente 37 %. Las mejoras de RMSE fueron 57 % en masa, 15 % en SFR y 7 % en D4000. Frente a la referencia Katachi utilizada en el proyecto, las reducciones fueron 56 %, 17 % y 32 %, respectivamente. La Figura 5 sitúa el resultado respecto de las referencias y los objetivos establecidos. La Tabla 15, en el Anexo E, reúne los valores y umbrales completos.

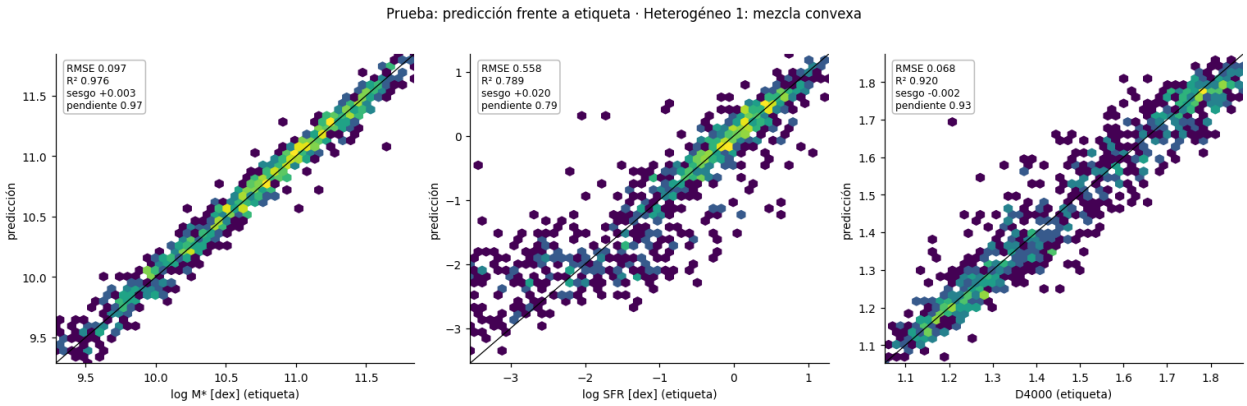


Figura 4: Predicciones del ensamble frente a las etiquetas de referencia en prueba. La diagonal representa coincidencia ideal; la densidad permite identificar la concentración de observaciones. Masa y D4000 mantienen una relación cercana a la diagonal, mientras SFR presenta mayor dispersión. Fuente: Avance 5.

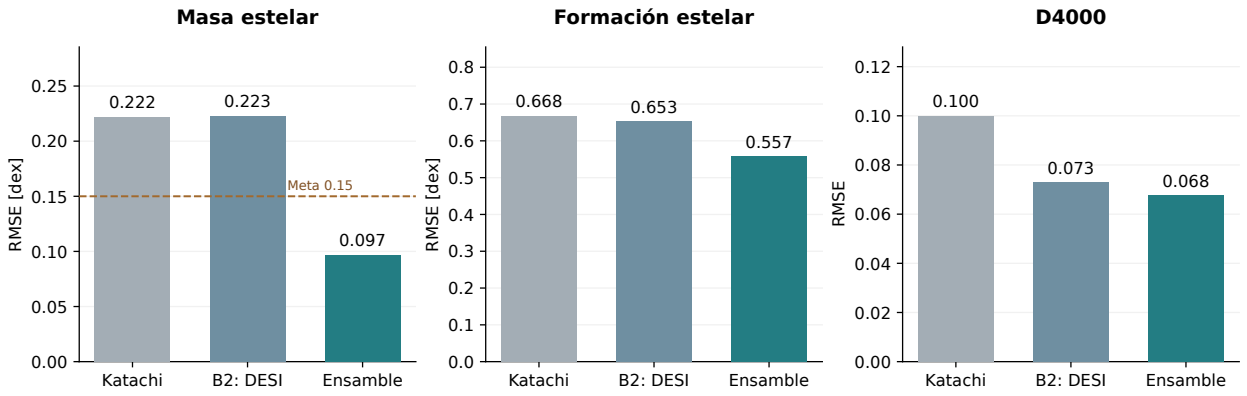


Figura 5: Evolución del RMSE desde Katachi y B2 hasta el ensamble seleccionado. Cada panel corresponde a una propiedad y utiliza su propia escala vertical. La línea punteada señala la meta de 0.15 dex para masa. Elaboración propia con las métricas del proyecto.

4.2. Generalización y comparación estadística

El criterio pasó de 0.1037 en validación a 0.1102 en prueba, un incremento cercano a 6 %. Para analizar la mejora frente a alternativas se aplicó bootstrap pareado con 2,000 remuestreos de galaxias. Cada remuestreo mantuvo los mismos objetos para ambos modelos, de modo que la diferencia reflejara su desempeño relativo sobre una muestra común.

Respecto de DINOv3 individual, el ensamble redujo el criterio aproximadamente 9 %. La diferencia fue -0.0115, con un intervalo de confianza de 95 % de $[-0.0158, -0.0070]$. También se observaron mejoras significativas frente a los homogéneos de DINOv3 y EfficientNet. En las comparaciones con el meta-aprendiz y el homogéneo de ConvNeXt, los intervalos incluyeron cero. El desempeño de este último, junto con su menor costo de inferencia, justifica conservarlo como alternativa operativa. La mezcla convexa se mantiene como modelo final conforme a la selección realizada en validación. Los resultados completos se presentan en el Anexo E.

4.3. Efecto de las entradas y de los miembros del ensamble

Las ablaciones de DINOv3 y ConvNeXt mostraron que incorporar redshift reduce el RMSE de masa entre 0.106 y 0.123 dex en las comparaciones por semilla. En SFR, la reducción fue de 0.031 a 0.045 dex, mientras D4000 cambió poco. La Figura 6 muestra, además, una menor tendencia del residuo de masa con la distancia. La prueba de permutación fue consistente con este comportamiento: alterar el redshift afectó principalmente la masa.

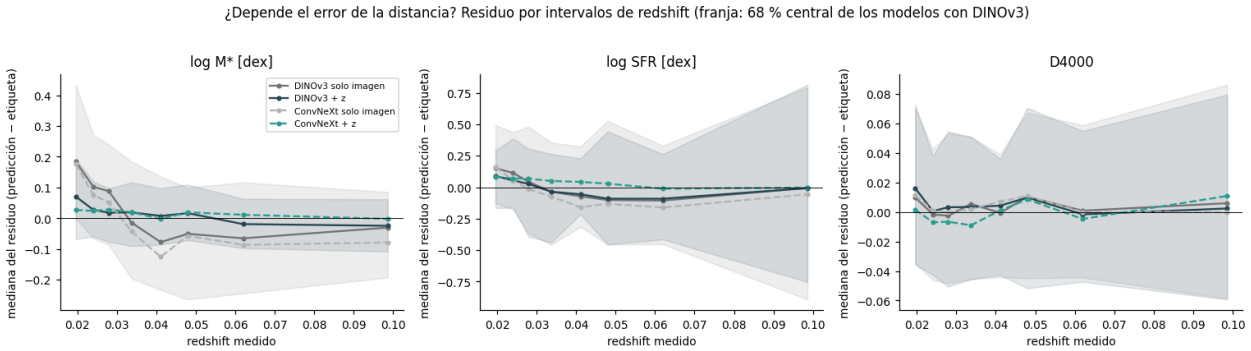


Figura 6: Residuo en validación por intervalo de redshift, con y sin esta entrada. La incorporación de información de distancia reduce la tendencia sistemática en masa. La comparación utiliza las mismas arquitecturas y semillas. Fuente: cuaderno de modelos base.

Al retirar miembros del ensamble, el mayor efecto de DINOv3 se observó en SFR y D4000, mientras ConvNeXt contribuyó a la estimación de masa y al desempeño conjunto. La contribución incremental de EfficientNet fue menor. Estos resultados, presentados en la Figura 7, explican la complementariedad de las arquitecturas y motivan evaluar un ensamble más compacto en una siguiente versión.

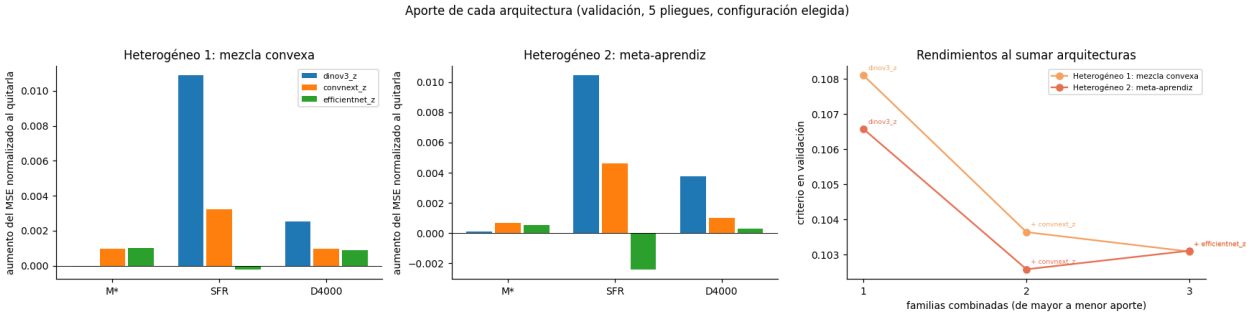


Figura 7: Aporte de las arquitecturas al ensamble en validación. Los dos primeros paneles muestran el cambio de error al retirar un miembro; el tercero, el comportamiento al incorporar arquitecturas. Fuente: cuaderno de ensambles heterogéneos.

Las correlaciones entre los residuos de las arquitecturas variaron de 0.86 a 0.93. Aunque sus diferencias permiten mejorar el promedio, la correlación elevada limita cuánto puede aportar un combinador más flexible. Esto concuerda con la proximidad observada entre la mezcla convexa y el promedio uniforme.

4.4. Estructura del error e interpretación técnica

Las pendientes de predicción frente a etiqueta fueron 0.97 para masa y 0.93 para D4000, con sesgos de $+0.003$ dex y -0.002, respectivamente. En SFR, la pendiente de 0.79 indica una mayor compresión de las predicciones hacia valores centrales. Este comportamiento se concentra en las galaxias con formación estelar muy baja, donde los miembros comparten parte del sesgo y su combinación no logra eliminarlo.

La Figura 10, en el Anexo F, muestra cómo varía el error a lo largo de cada propiedad y del redshift. Los análisis de oclusión complementaron esta evaluación: DINOv3 resultó más sensible a la región central de la galaxia que al fondo lejano. El Anexo F presenta estas pruebas y su relación con las señales de desacuerdo entre modelos.

El desacuerdo entre arquitecturas se correlacionó con el error absoluto de SFR, con ρ de Spearman de 0.40. Esta relación permite utilizarlo como señal auxiliar para ordenar los casos que requieren revisión. Su conversión en intervalos predictivos calibrados queda como una línea de trabajo posterior.

4.5. Discusión de los resultados

Los experimentos permiten distinguir el efecto de la información de entrada, la adaptación de las representaciones y la combinación de modelos. El redshift produjo la mayor mejora en masa; el ajuste de los extractores fortaleció la estimación de SFR y D4000; y el ensamble redujo el error conjunto. La secuencia de comparaciones explica el desempeño final y ayuda a establecer qué componentes conviene mantener en futuras versiones.

En DINOv3, LoRA permitió adaptar una representación de gran capacidad ajustando una fracción de sus parámetros. Los regresores clásicos ofrecieron referencias de menor costo y las CNN modernas mostraron una relación favorable entre precisión y tiempo de inferencia. En conjunto, los resultados permiten valorar estas alternativas según las propiedades que se desea estimar y los recursos disponibles para procesar el catálogo.

5. Implementación y operación

5.1. Producto y arquitectura de inferencia propuesta

Se propone entregar las predicciones en un catálogo versionado que incluya las tres propiedades, el identificador de cada galaxia, las señales de calidad y la versión del modelo. El procesamiento por lotes permite organizar los recursos de cómputo y almacenamiento de acuerdo con el tamaño del catálogo. La implementación reutilizaría los componentes desarrollados en PyTorch [23] y seguiría prácticas de MLOps para conservar la correspondencia entre datos, modelos y resultados [24, 25].

La Figura 13, en el Anexo H, presenta el flujo propuesto, desde la recepción de las entradas hasta la publicación del catálogo. Un registro central conservaría los pesos de las redes, las transformaciones de entrada y la configuración del combinador, de modo que cada predicción pudiera reproducirse con la versión correspondiente.

Las observaciones que no cumplan los requisitos de entrada se registrarían junto con el motivo del rechazo. El preprocesamiento emplearía constantes fijas, evitando que una predicción dependa de los demás objetos del lote. Antes de publicar una nueva versión, se comprobaría que las predicciones de referencia se reproducen y que el catálogo queda vinculado al código, los pesos y las transformaciones utilizados.

5.2. Costo computacional y alternativas de servicio

La ejecución de las nueve redes tomó 10.619 ms por galaxia sin TTA en una NVIDIA A100. Extrapolado a un millón de objetos, este tiempo equivale a 2.95 horas de GPU. Al conservar las ocho transformaciones del TTA, la estimación aumenta a aproximadamente 23.6 horas, bajo la misma hipótesis de escalamiento. El tiempo total de procesamiento incluiría también la lectura de las imágenes, su preparación y la escritura de resultados.

El homogéneo de ConvNeXt requiere tres redes y 1.354 ms por galaxia sin TTA, aproximadamente 7.8 veces menos que la mezcla, con un criterio de prueba de 0.1120. Se propone conservarlo como alternativa para lotes de gran volumen o presupuestos de cómputo limitados. En ambas configuraciones, el TTA debe especificarse como parte del servicio, pues las métricas finales se obtuvieron con ese procedimiento.

Cada tensor de tres bandas, 300×300 píxeles y 32 bits por valor ocupa aproximadamente 1.08 MB sin compresión. Cargar las imágenes por lotes y liberarlas después de generar las predicciones permite limitar el uso de memoria. Durante el piloto se deberá medir el efecto del tamaño de lote, la GPU y la velocidad de lectura y escritura sobre el rendimiento total.

5.3. Requisitos y responsables

La Tabla 19, en el Anexo H, reúne los requisitos de implementación y los responsables propuestos para dar continuidad al trabajo. El equipo de ciencia de datos mantendría el código y los modelos; infraestructura administraría el cómputo y el almacenamiento; y los asesores científicos revisarían el uso y la interpretación de los catálogos.

5.4. Monitoreo y mantenimiento

El monitoreo abarcaría la calidad de las entradas, los cambios en sus distribuciones y el comportamiento de las predicciones. Cuando se disponga de nuevas etiquetas, se evaluaría también el error. Un cambio de distribución puede motivar una revisión, pero su efecto en la precisión debe comprobarse con observaciones etiquetadas [26]. La Tabla 20, en el Anexo H, presenta umbrales iniciales que se ajustarían durante los primeros lotes.

Cada actualización conservaría el protocolo experimental: ajuste y selección con datos de desarrollo, registro de la configuración y evaluación en una muestra reservada. La primera implementación utilizaría entradas compatibles con las del proyecto. Su extensión a otros levantamientos requeriría estudiar los cambios de dominio y la disponibilidad de las variables de entrada.

6. Conclusiones clave

El ensamble de DINOv3 con LoRA, ConvNeXt-Tiny y EfficientNet-B3 permitió estimar simultáneamente masa estelar, SFR y D4000 a partir de imágenes multibanda y redshift. En prueba obtuvo un criterio de 0.1102 y RMSE de 0.0969 dex, 0.5575 dex y 0.0676, respectivamente. Estos resultados representan una reducción de 37 % en el error conjunto frente a la línea base del proyecto y satisfacen la meta de 0.15 dex para masa.

Las comparaciones identificaron tres factores asociados con la mejora: conservar las diferencias de señal entre galaxias durante la preparación, incorporar información de distancia y adaptar las representaciones preentrenadas. La combinación de arquitecturas añadió una reducción del error que se evaluó con un protocolo común, múltiples semillas y bootstrap pareado. El registro de las configuraciones y las predicciones permite reproducir la evaluación del modelo seleccionado.

La principal dificultad permanece en la SFR de galaxias con formación estelar muy baja. El análisis de residuos permite concentrar las siguientes pruebas en esa población, mientras que la ablación de miembros y los tiempos de inferencia orientan la búsqueda de configuraciones más compactas. La Tabla 21, en el Anexo H, resume las líneas propuestas para continuar el trabajo.

Los modelos y las transformaciones desarrollados ofrecen una base para procesar catálogos por lotes. El siguiente paso es evaluar su operación en un piloto, verificar la reproducción de las predicciones y ajustar los mecanismos de seguimiento con los investigadores que utilizarán los resultados.

Declaración de uso de inteligencia artificial

En los cuadernos del proyecto se utilizaron herramientas de Anthropic y OpenAI como apoyo para partes del código y la redacción, conforme a las declaraciones de cada entrega. En la preparación y revisión de este artículo se utilizaron Claude y ChatGPT/Codex para organizar el contenido a partir de los cuadernos, mejorar su explicación técnica, apoyar el formato en LaTeX y elaborar figuras de síntesis. Esta revisión conserva los resultados experimentales reportados; no incorpora nuevos entrenamientos. La responsabilidad de la versión entregada corresponde a los autores.

Referencias

[1] Ž. Ivezić, S. M. Kahn, J. A. Tyson, *et al.*, "LSST: From science drivers to reference design and anticipated data products," *The Astrophysical Journal*, vol. 873, no. 2, p. 111, 2019. https://doi.org/10.3847/1538-4357/ab042c.

[2] J. P. Alfonzo, K. G. Iyer, M. Akiyama, *et al.*, "Katachi: Decoding the imprints of past star formation on present-day morphology in galaxies with interpretable CNNs," *The Astrophysical Journal*, vol. 967, no. 2, p. 152, 2024. https://doi.org/10.3847/1538-4357/ad3b95.

[3] S. Studer, T. B. Bui, C. Drescher, *et al.*, "Towards CRISP-ML(Q): A machine learning process model with quality assurance methodology," *Machine Learning and Knowledge Extraction*, vol. 3, no. 2, pp. 392–413, 2021. https://doi.org/10.3390/make3020020.

[4] J. C. Roediger and S. Courteau, "On the uncertainties of stellar mass estimates via colour measurements," *Monthly Notices of the Royal Astronomical Society*, vol. 452, no. 3, pp. 3209–3225, 2015. https://doi.org/10.1093/mnras/stv1499.

[5] A. Dey, D. J. Schlegel, D. Lang, *et al.*, "Overview of the DESI Legacy Imaging Surveys," *The Astronomical Journal*, vol. 157, no. 5, p. 168, 2019. https://doi.org/10.3847/1538-3881/ab089d.

[6] K. Bundy, M. A. Bershady, D. R. Law, *et al.*, "Overview of the SDSS-IV MaNGA survey: Mapping nearby galaxies at apache point observatory," *The Astrophysical Journal*, vol. 798, no. 1, p. 7, 2015. https://doi.org/10.1088/0004-637X/798/1/7.

[7] S. F. Sánchez, J. K. Barrera-Ballesteros, E. Lacerda, *et al.*, "SDSS-IV MaNGA: pyPipe3D analysis release for 10,000 galaxies," *The Astrophysical Journal Supplement Series*, vol. 262, no. 2, p. 36, 2022. https://doi.org/10.3847/1538-4365/ac7b8f.

[8] R. Lupton, M. R. Blanton, G. Fekete, *et al.*, "Preparing red-green-blue images from CCD data," *Publications of the Astronomical Society of the Pacific*, vol. 116, no. 816, pp. 133–137, 2004. https://doi.org/10.1086/382245.

[9] G. C. Cawley and N. L. C. Talbot, "On over-fitting in model selection and subsequent selection bias in performance evaluation," *Journal of Machine Learning Research*, vol. 11, pp. 2079–2107, 2010. https://jmlr.org/papers/v11/cawley10a.html.

[10] E. N. Taylor, A. M. Hopkins, I. K. Baldry, *et al.*, "Galaxy And Mass Assembly (GAMA): stellar mass estimates," *Monthly Notices of the Royal Astronomical Society*, vol. 418, no. 3, pp. 1587–1620, 2011. https://doi.org/10.1111/j.1365-2966.2011.19536.x.

[11] K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pp. 770–778, 2016.

[12] R. Caruana, "Multitask learning," *Machine Learning*, vol. 28, pp. 41–75, 1997. https://doi.org/10.1023/A:1007379606734.

[13] Z. Liu, H. Mao, C.-Y. Wu, C. Feichtenhofer, T. Darrell, and S. Xie, "A ConvNet for the 2020s," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 11976–11986, 2022.

[14] O. Siméoni, H. V. Vo, M. Seitzer, *et al.*, "DINOv3." arXiv:2508.10104, 2025. https://doi.org/10.48550/arXiv.2508.10104.

[15] E. J. Hu, Y. Shen, P. Wallis, *et al.*, "LoRA: Low-rank adaptation of large language models," in *International Conference on Learning Representations*, 2022. https://arxiv.org/abs/2106.09685.

[16] M. Tan and Q. V. Le, "EfficientNet: Rethinking model scaling for convolutional neural networks," in *Proceedings of the 36th International Conference on Machine Learning*, vol. 97, pp. 6105–6114, 2019.

[17] P. J. Huber, "Robust estimation of a location parameter," *The Annals of Mathematical Statistics*, vol. 35, no. 1, pp. 73–101, 1964. https://doi.org/10.1214/aoms/1177703732.

[18] T. Akiba, S. Sano, T. Yanase, T. Ohta, and M. Koyama, "Optuna: A next-generation hyperparameter optimization framework," in *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pp. 2623–2631, 2019.

[19] A. Krogh and J. Vedelsby, "Neural network ensembles, cross validation, and active learning," in *Advances in Neural Information Processing Systems 7*, pp. 231–238, MIT Press, 1995.

[20] D. H. Wolpert, "Stacked generalization," *Neural Networks*, vol. 5, no. 2, pp. 241–259, 1992. https://doi.org/10.1016/S0893-6080(05)80023-1.

[21] L. Breiman, "Stacked regressions," *Machine Learning*, vol. 24, pp. 49–64, 1996. https://doi.org/10.1007/BF00117832.

[22] T. Hastie, R. Tibshirani, and J. Friedman, *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. Springer, 2 ed., 2009. https://doi.org/10.1007/978-0-387-84858-7.

[23] A. Paszke, S. Gross, F. Massa, *et al.*, "PyTorch: An imperative style, high-performance deep learning library," in *Advances in Neural Information Processing Systems 32*, pp. 8024–8035, 2019.

[24] D. Kreuzberger, N. Kühl, and S. Hirschl, "Machine learning operations (MLOps): Overview, definition, and architecture," *IEEE Access*, vol. 11, pp. 31866–31879, 2023. https://doi.org/10.1109/ACCESS.2023.3262138.

[25] D. Sculley, G. Holt, D. Golovin, *et al.*, "Hidden technical debt in machine learning systems," in *Advances in Neural Information Processing Systems 28*, pp. 2503–2511, 2015.

[26] S. Rabanser, S. Günnemann, and Z. C. Lipton, "Failing loudly: An empirical study of methods for detecting dataset shift," in *Advances in Neural Information Processing Systems 32*, 2019.

A. Recorrido del proyecto y soporte experimental

La Tabla 8 resume la secuencia de desarrollo. Los avances y los cuadernos especializados contienen las configuraciones, el código, las salidas y los análisis que sustentan las decisiones del proyecto.

Etapa	Evidencia principal	Decisión resultante
Comprensión del problema	Antecedente Katachi y propiedades objetivo.	Formular regresión supervisada con imágenes y etiquetas espectroscópicas.
EDA	Distribuciones de etiquetas, cobertura, calidad y tamaño angular.	Selección de calidad, recorte de 300 píxeles y evaluación por grupos.
Ingeniería de datos	Comparación de transformaciones y 51 características iniciales.	Escalas globales y estudio de información de distancia.
Línea base	B1 fotométrico y B2 basado en Katachi.	Fijar referencias y meta de masa de 0.15 dex.
Modelos candidatos	Seis alternativas, ablaciones y optimización.	Adaptar las representaciones e integrar redshift.
Ensambles	Promedios por semilla, mezcla convexa y meta-aprendiz.	Seleccionar mezcla convexa mediante criterio y complejidad.
Evaluación final	Métricas en prueba, bootstrap, residuos y costo.	Definir modelo principal y propuesta de operación por lotes.

Tabla 8: Secuencia de desarrollo y evidencia producida.

Cuadernos	Contenido
Avances 1 y 2	EDA, calidad, preparación de imágenes e ingeniería de características.
Avance 3 y baseline ampliado	Referencias de imagen y fotometría, métricas y criterios de éxito.
Modelo 1	ResNet50 multitarea, variantes A–G, RGB/GRZ, redshift y Huber.
Modelos 2, 5 y 6	SVR, Ridge y KNN sobre características visuales.
Modelos 3 y 4	ConvNeXt-Tiny y DINOv3; optimización, ajuste fino y análisis.
Avance 4	Comparación y selección de candidatos.
Modelos base del Avance 5	DINOv3, ConvNeXt y EfficientNet con redshift.
Ensambles homogéneos	Promedio y ponderación de semillas de ResNet50.
Ensambles heterogéneos	Mezcla convexa, meta-aprendiz, validación anidada y ablaciones.
Avance 5	Selección final, evaluación en prueba, análisis de errores y costos.

Tabla 9: Cuadernos de soporte y contenido técnico.

B. Muestra y transformaciones

Etapa	Entrenamiento	Validación	Prueba	Total
Catálogo candidato	7,390	1,302	969	9,661
Selección `QCFLAG=0`	7,123	1,262	918	9,303
Integridad de bandas	7,122	1,261	917	9,300
Muestra final de modelado	7,121	1,261	917	9,299
Baseline fotométrico ampliado	5,122	899	635	6,656

Tabla 10: Conteos documentados durante la preparación de la muestra.

Fuente: Avances y baseline ampliado. B2 utiliza la partición de la etapa de línea base; la evaluación del ensamble corresponde a la muestra final de modelado.

Componente	Operación	Propósito
Recorte	Centro de 300×300 píxeles a escala nativa.	Reducir tamaño de entrada preservando la región galáctica.
GRZ	$a_b = \operatorname{asinh}(f_b/s_b)$ y estandarización por banda; s_b estimado con entrenamiento.	Comprimir rango dinámico conservando diferencias entre objetos.
Lupton	Composición multibanda y recorte de 288 píxeles para DINOv3.	Adaptar la representación al extractor visual.
Etiquetas	$\tilde{y}_k = (y_k - \mu_k)/\sigma_k$.	Entrenar tres objetivos en escalas comparables.
Redshift	Estandarización con parámetros de entrenamiento.	Integrar la variable contextual al vector de características.
Aumentos	Giros de 90° y reflejos.	Explorar orientaciones preservando las etiquetas.
TTA	Promedio de ocho simetrías en inferencia.	Reducir sensibilidad a la orientación.
Identidad	Alineación por `mangaid` y comprobación de huellas.	Mantener correspondencia entre entradas, etiquetas y predicciones.

Tabla 11: Transformaciones y controles utilizados para el modelado.

Fuente: Cuadernos de preparación y modelos base. Las constantes de cada configuración se conservan con el modelo.

El baseline fotométrico B1 seleccionó regresión lineal para masa y Random Forest para SFR y D4000 mediante validación cruzada sobre entrenamiento. La relación final de masa fue $\widehat{\log M_\star} = 2.055405 + 0.238474(g-i) - 0.4M_i$. Sus RMSE de prueba fueron 0.14114 dex, 0.91800 dex y 0.11711, respectivamente. La comparación aportó una referencia sobre el poder predictivo de dos variables fotométricas antes de incorporar la distribución espacial de la imagen.

C. Modelos candidatos y ablaciones

Variante	Arquitectura y representación	Entradas y pérdida	C	Desv.
A	Tres redes separadas; RGB	Imagen; MSE	0.1838	0.0019
B	Extractor compartido; RGB	Imagen; MSE	0.1824	0.0035
C	Extractor compartido; RGB	Imagen + z; MSE	0.1355	0.0038
D	Extractor compartido; GRZ	Imagen + z; MSE	0.1286	0.0019
E	Extractor compartido; GRZ	Imagen + z; Huber	0.1269	0.0015
F	Extractor compartido; GRZ	Imagen; MSE	0.1781	0.0047
G	Extractor compartido; GRZ	Imagen; Huber	0.1795	0.0037

Tabla 12: Variantes de ResNet50, con criterio medio y desviación entre tres semillas.
Fuente: Modelo 1. Las variantes F y G completan los contrastes de redshift y pérdida.

Modelo	Entradas	C	Masa	SFR	D4000
ResNet50 E	Imagen + z	0.128	0.109	0.598	0.073
DINOv3 + LoRA	Imagen	0.152	0.221	0.587	0.070
ConvNeXt-Tiny	Imagen	0.163	0.228	0.607	0.073
Ridge	Vector + z	0.387	0.242	0.916	0.153
SVR	Vector + z	0.442	0.266	0.983	0.161
KNN	Vector + z	0.628	0.426	1.083	0.185

Tabla 13: Modelos candidatos en validación, en la etapa previa al ensamble.
Fuente: Avance 4. Vector: características visuales; z: redshift. Últimas tres columnas: RMSE; masa y SFR en dex.

Antes del ajuste con LoRA se compararon tamaños de DINOv3, formas de presentar la imagen y resúmenes de los tokens. La Figura 8 presenta los resultados de esta exploración.

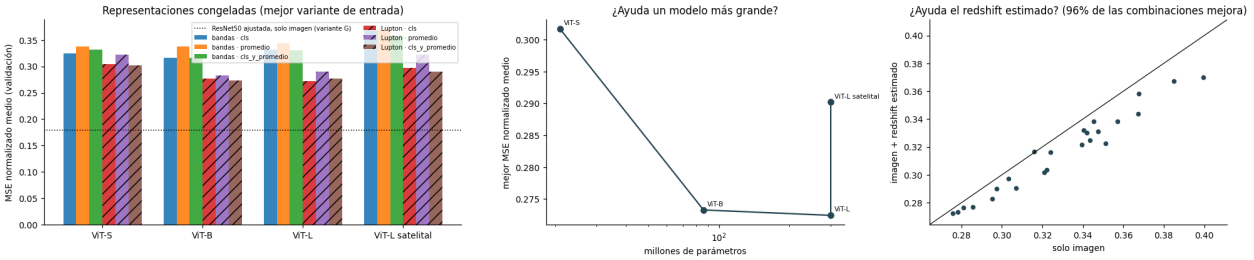


Figura 8: Exploración de representaciones congeladas de DINOv3 en validación. Los paneles comparan configuración de la representación, tamaño del extractor y efecto del redshift estimado. Fuente: Modelo 4.

D. Configuración de entrenamiento

La Tabla 14 reúne las configuraciones de entrenamiento. En todos los casos se calcularon las transformaciones con el conjunto de entrenamiento y se utilizaron tres semillas. En las redes con redshift, esta variable se concatena al vector visual antes de las cabezas de regresión.

Elemento	ResNet50 E	ConvNeXt-Tiny	DINOv3	EfficientNet-B3
Preentrenamiento	ImageNet	ImageNet	DINOv3, autosupervisado	ImageNet
Entrada visual	GRZ, 300 px	GRZ, 300 px	Lupton, 288 px	GRZ, 300 px
Parámetros entrenables	25.1 M	28.4 M	5.1 M de 308 M; LoRA, rango 32	Aproximadamente 12 M
Optimizador	AdamW	AdamW	AdamW	AdamW
Tasa de aprendizaje	Extractor 3×10^{-5}; cabezas 3×10^{-4}	Extractor del orden de 3–5×10^{-4}; tasas por capa	Adaptadores del orden de 2.3×10^{-4}	Extractor 6.1×10^{-4}; cabezas $\times8.34$
Programa	Apertura gradual, hasta 100 épocas y parada temprana	30 épocas; calentamiento y descenso coseno	20 épocas; calentamiento y descenso coseno	20 épocas; calentamiento y descenso coseno
Pérdida	Huber, $\delta = 1$	MSE	Huber, $\delta = 1$	Huber, $\delta = 1$
Búsqueda	Variantes A–G	30 pruebas Optuna	Exploración congelada y 16 pruebas de ajuste	12 pruebas Optuna
Tiempo y equipo	RTX A4000	6.1 min, A100	24.0 min, A100	6.4 min, A100

Tabla 14: Configuración de las redes empleadas en el desarrollo y el ensamble.
Fuente: Cuadernos de modelos y modelos base. Los tiempos excluyen búsquedas de hiperparámetros.

La configuración ganadora de EfficientNet-B3 utilizó *weight decay* de 0.00112, decaimiento de tasa por capa de 0.98796, *drop path* de 0.24973 y una época de calentamiento. La optimización con poda permitió concentrar cómputo en configuraciones prometedoras. Los modelos de DINOv3 y ConvNeXt con redshift conservaron las configuraciones seleccionadas en la etapa anterior.

Para la mezcla convexa se exploraron $\lambda \in \{0, 0.001, 0.01, 0.1, 1, 10\}$ y pesos globales o por propiedad. La configuración final fue por propiedad con $\lambda = 0.01$. Su criterio en validación anidada fue 0.1037 ± 0.0002 entre repeticiones. El meta-aprendiz obtuvo 0.1046 ± 0.0003.

E. Resultados completos e intervalos

Referencia	C	RMSE masa	RMSE SFR	RMSE D4000
Predictor de la media	1.004	0.628	1.217	0.239
Katachi	0.206	0.222	0.668	0.100
B2: Katachi con DESI	0.175	0.223	0.653	0.073
Mezcla convexa	**0.110**	**0.097**	**0.558**	**0.068**
Umbral de referencia: Katachi + margen	–	0.242	0.688	0.110
Meta deseable de masa	–	0.150	–	–

Tabla 15: Resultado final frente a las líneas base y a los umbrales del proyecto.
Fuente: Línea base y evaluación final. Masa y SFR en dex; D4000 adimensional. Los conteos de las etapas se reúnen en el Anexo B.

Modelo	C	RMSE masa	RMSE SFR	RMSE D4000
Mezcla convexa	0.1102	0.0969	0.5575	0.0676
Homogéneo ConvNeXt	0.1120	0.1011	0.5545	0.0702
Meta-aprendiz	0.1124	0.0959	0.5644	0.0682
Homogéneo DINOv3	0.1193	0.1059	0.5799	0.0694
DINOv3 individual	0.1217	0.1090	0.5835	0.0704
Homogéneo EfficientNet	0.1242	0.0989	0.5962	0.0710

Tabla 16: Modelos de la comparación final en las 917 galaxias de prueba.
Fuente: Avance 5. Modelo seleccionado en validación: mezcla convexa.

Alternativa	ΔC	IC 95 %
Homogéneo EfficientNet	-0.0140	$[-0.0198, -0.0087]$
DINOv3 individual	-0.0115	$[-0.0158, -0.0070]$
Homogéneo DINOv3	-0.0091	$[-0.0129, -0.0052]$
Meta-aprendiz	-0.0022	$[-0.0046, 0.0000]$
Homogéneo ConvNeXt	-0.0018	$[-0.0057, +0.0019]$

Tabla 17: Diferencias pareadas de criterio: modelo final menos alternativa.
Fuente: Bootstrap pareado con 2,000 remuestreos de galaxias. Valores negativos favorecen a la mezcla convexa.

La Figura 9 complementa la tabla con la comparación entre validación y prueba.

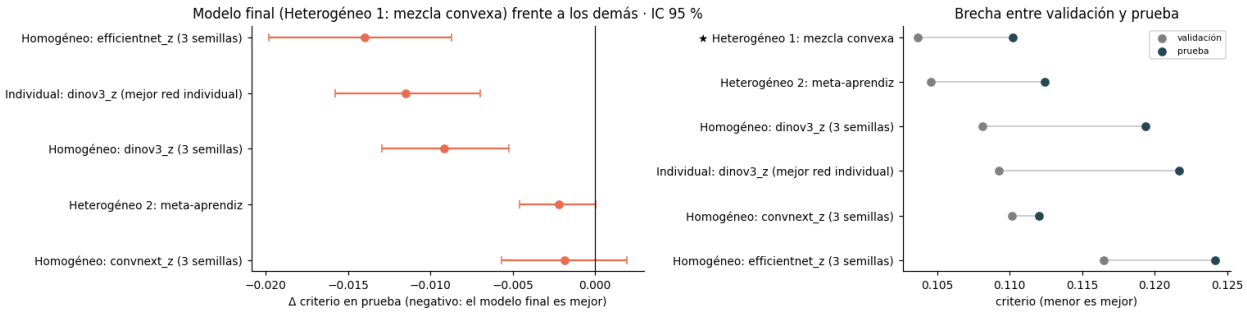


Figura 9: Izquierda: diferencias de criterio e intervalos del 95 %. Derecha: criterio en validación y prueba por modelo. Fuente: Avance 5.

F. Interpretación y señales de confiabilidad

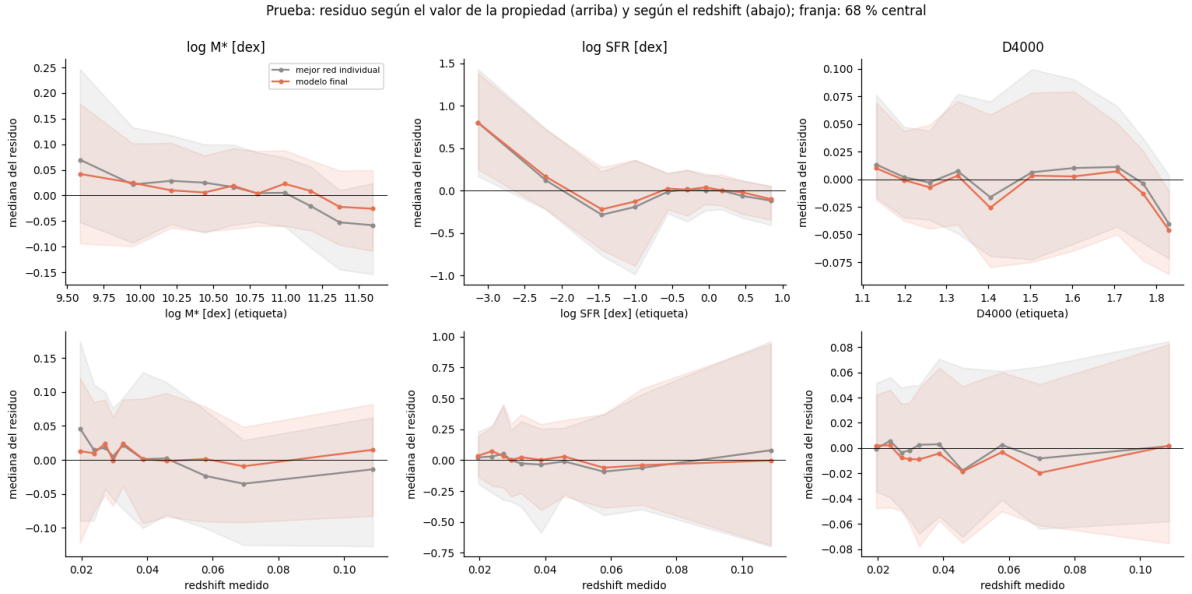


Figura 10: Mediana y dispersión de los residuos en prueba según el valor de la propiedad y el redshift. Se compara DINOv3 individual con la mezcla convexa. El análisis por intervalos permite localizar tendencias que una métrica global resume en una sola cifra. Fuente: Avance 5.

La oclusión evalúa cuánto cambia el error al suprimir parte de la información de entrada. En DINOv3, ocultar la región dentro de $0.5R_{50}$ aumentó el RMSE de masa en aproximadamente 0.31 dex, mientras las regiones más allá de $4R_{50}$ tuvieron un efecto pequeño. R_{50} es el radio que contiene la mitad de la luz. La Figura 11 reúne los resultados por banda y región.

La Figura 12 relaciona el error con el desacuerdo entre arquitecturas. En SFR, esta señal permite identificar grupos de observaciones de mayor dificultad y fundamenta su inclusión como campo auxiliar del catálogo propuesto.

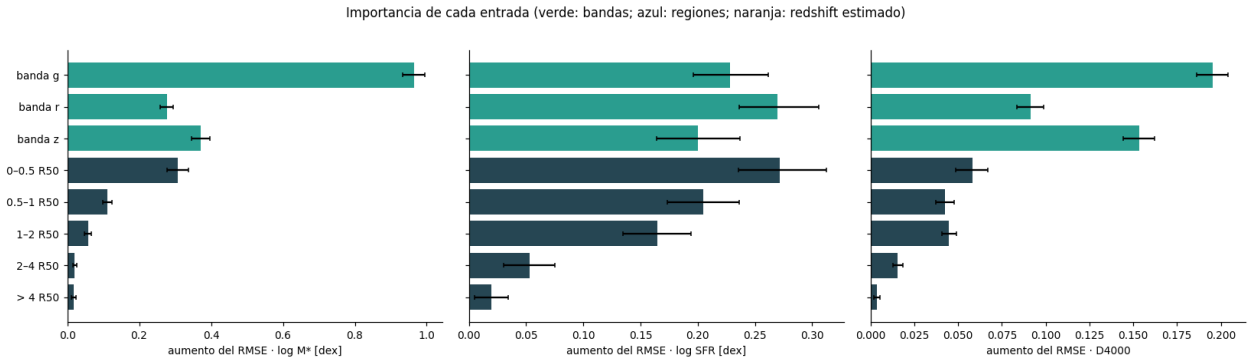


Figura 11: Aumento del RMSE de validación al suprimir bandas o regiones de la entrada de DINOv3. En la composición de Lupton, una intervención sobre una banda modifica también la representación conjunta de color. Fuente: Modelo 4.

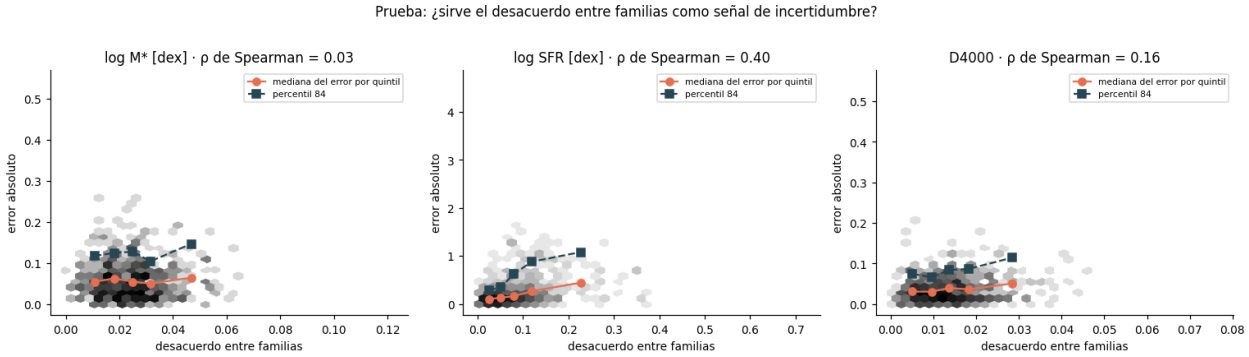


Figura 12: Error absoluto del modelo final frente al desacuerdo entre arquitecturas. Las curvas resumen la mediana y el percentil 84 del error por quintil de desacuerdo. Fuente: Avance 5.

G. Registro de reproducibilidad

Elemento	Valor
Repositorio del equipo	https://github.com/erteck/InferenciaPropiedadesFisicas
Commit del registro	`6a22755fcbd9`
Huella de predicciones de miembros	`f232e1eafa88717b`
Registro de apertura de prueba	1 de noviembre de 2026, 00:47 UTC
Miembros	DINOv3 ViT-L/16 con LoRA, ConvNeXt-Tiny y EfficientNet-B3
Entradas	Imagen multibanda y redshift espectroscópico
Semillas	42, 7 y 2026
Combinador	Mezcla convexa, pesos por propiedad, $\lambda = 0.01$
Muestra de evaluación	1,261 galaxias en validación; 917 en prueba
Desviaciones del criterio	0.6467 para masa, 1.1613 para SFR, 0.2427 para D4000
Hardware de costos	NVIDIA A100-SXM4-40GB
Inferencia de las métricas finales	Promedio de ocho simetrías por red

Tabla 18: Elementos conservados para reproducir la evaluación final.
Fuente: Cuadernos de ensambles y comparación final.

Las huellas permiten comprobar que las predicciones de los miembros corresponden a las utilizadas para ajustar el combinador. Junto con los pesos de las redes, las escalas de entrenamiento y la versión del código, este registro permite reproducir la inferencia y detectar cambios entre corridas.

H. Operación propuesta y continuidad del proyecto

El flujo propuesto organiza la inferencia por lotes y conserva la relación entre entradas, modelos y resultados. Las tablas siguientes detallan los requisitos, las respuestas de monitoreo y las líneas de trabajo posteriores.

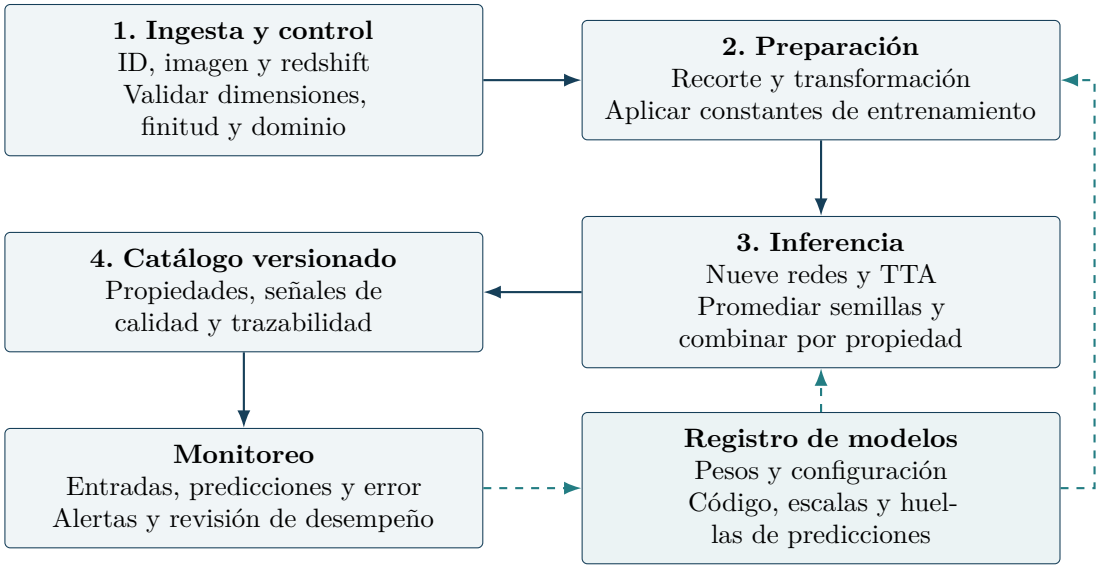


Figura 13: Arquitectura propuesta para operar por lotes. Las flechas continuas representan el flujo de procesamiento; las discontinuas conectan configuración, monitoreo y revisión de versiones. Elaboración propia.

Requisito	Implementación propuesta	Responsable
Contrato de entrada	Identificador, recortes GRZ y redshift; comprobaciones automáticas.	Ciencia de datos
Entorno reproducible	Dependencias fijadas y contenedor de inferencia con PyTorch.	Ciencia de datos e infraestructura
Registro de modelos	Pesos de nueve redes, escalas, pesos del combinador, versión de código y huellas.	Ciencia de datos
Procesamiento por lotes	Carga en flujo, control de memoria y medición de rendimiento.	Infraestructura
Catálogo de salida	Predicciones, desacuerdo, marcas de calidad y versión.	Ciencia de datos y asesores
Validación de versión	Reproducción de predicciones de referencia y evaluación antes de publicar.	Ciencia de datos
Aceptación científica	Revisión de poblaciones y de observaciones marcadas.	Asesores del IA-UNAM

Tabla 19: Requisitos propuestos para la operación del modelo.

Señal	Regla inicial de alerta	Acción
Integridad de entrada	Más de 1 % de recortes rechazados en un lote.	Revisar la adquisición y la preparación.
Distribución de imágenes	PSI mayor que 0.2 en ruido o brillo por banda y región.	Examinar el lote y evaluar objetos con etiqueta del dominio afectado.
Dominio del redshift	Valores fuera del intervalo de entrenamiento.	Marcar extrapolación para revisión.
Desacuerdo de miembros	Más de 20 % del lote supera el percentil 90 del desacuerdo de SFR en validación.	Revisar cambios de población o dificultad de las entradas.
Desempeño con etiquetas	RMSE mayor que 0.12 dex en masa, 0.65 dex en SFR o 0.08 en D4000.	Revisar preparación, recalibrar o reentrenar y validar una nueva versión.

Tabla 20: Plan de monitoreo propuesto y respuesta ante alertas.
Fuente: Propuesta operativa derivada del proyecto. Los umbrales son parámetros iniciales del piloto.

Línea	Objetivo técnico	Evaluación propuesta
Mejorar SFR	Explorar información de color y UV, calidad de etiquetas y formulaciones alternativas del objetivo.	Ablaciones por fuente de información y métricas por población, con apoyo de los asesores.
Simplificar el ensamble	Evaluar una versión DINOv3 + ConvNeXt y la configuración homogénea de menor costo.	Aplicar la misma regla de selección y medir error, memoria y tiempo.
Cuantificar incertidumbre	Convertir señales de desacuerdo en estimaciones calibradas de confiabilidad.	Medir cobertura y amplitud de intervalos en datos reservados.
Extender el dominio	Evaluar redshift fotométrico de catálogo y adaptación a nuevas bandas o levantamientos.	Comparación por dominio y validación externa.
Operar un piloto	Empaquetar modelos y probar lotes con el flujo propuesto.	Reproducibilidad de predicciones, rendimiento y monitoreo.

Tabla 21: Siguientes iteraciones y forma propuesta de evaluarlas.