Inferencia de propiedades físicas de galaxias a partir de imágenes multibanda

Resumen ejecutivo

Integrantes: Luz Copelia Minutti Pérez, Erick Alberto Bustos Cruz Fecha: 15 de noviembre de 2026
Programa: Proyecto Integrador · Maestría en Inteligencia Artificial Aplicada · Equipo 24
Asesores: Dr. Iván Reyes Amezcua (Tec); Dr. Héctor Hernández Toledo y Dr. José A. Vázquez Mata (IA-UNAM)

Los astrónomos estudian la evolución de las galaxias a partir de tres propiedades: su masa en estrellas (masa estelar), la rapidez con que forma estrellas nuevas (tasa de formación estelar, SFR) y la edad de sus estrellas, resumida en el índice D4000. Todas se miden con espectroscopía, una técnica que descompone la luz de la galaxia y cuya observación es lenta y costosa. La medición más completa, de toda la galaxia y no solo de su centro, existe para unas 10,000 galaxias del proyecto MaNGA (Sánchez et al., 2022). El proyecto DESI ya cuenta con estimaciones para 6.7 millones de galaxias, pero provienen de espectros que cubren solo el centro y se corrigen para aproximar la galaxia completa (Li et al., 2026). El Instituto de Astronomía de la UNAM (IA-UNAM) necesita estimaciones de la galaxia completa, comparables con las de MaNGA, para las galaxias de DESI que se parecen a las de MaNGA.

Desarrollamos un modelo de inteligencia artificial que estima las tres propiedades con dos datos que DESI ya tiene: una imagen en tres filtros de color y el redshift, una medida de la distancia. Combina tres redes neuronales de visión (DINOv3, ConvNeXt-Tiny y EfficientNet-B3), entrenadas con 9,299 galaxias de MaNGA cuyas propiedades medidas sirvieron como respuestas correctas, y lo evaluamos una sola vez con 917 galaxias que no había visto (Minutti Pérez y Bustos Cruz, 2026). El producto sería un catálogo con las tres propiedades, un indicador de confiabilidad y la versión del modelo para cada galaxia.

0.0969 dex	**0.5575 dex**	**0.0676**	**−37 %**
Error de masa	Error de SFR	Error de D4000	Error conjunto
cerca de 25 %	factor cercano a 3.6	−32 % vs. Katachi	vs. referencia inicial

Los recuadros muestran el error típico (RMSE) en las 917 galaxias de prueba. Masa y SFR se miden en escala logarítmica y su error, en dex: 0.0969 dex equivale a equivocarse cerca de 25 % en la masa, mejor que la meta de 0.15 dex. El error conjunto de las tres propiedades bajó 37 % frente al modelo de referencia que construimos al inicio del proyecto. Frente a Katachi (Alfonzo et al., 2024), el modelo publicado más cercano, aplicado a las mismas galaxias, el error bajó 56 % en masa, 17 % en SFR y 32 % en D4000; la mejora en masa se debe sobre todo a usar la distancia, que Katachi no recibe. Combinar las tres redes redujo el error cerca de 9 % respecto de la mejor por sí sola, una diferencia estadísticamente significativa. La SFR es la propiedad más difícil: la estimación típica difiere del valor medido en un factor cercano a 3.6, sobre todo en galaxias que casi no forman estrellas. Cuando las redes discrepan entre sí, el error suele ser mayor (correlación de 0.40), lo que señala qué revisar.

Proponemos procesar en un solo lote las galaxias de DESI comparables con MaNGA, que estimamos en unos 2 millones, cifra que el piloto debe confirmar. El beneficio principal es la capacidad:

una GPU procesa ese lote en cuatro días, y el catálogo resultante tendría doscientas veces más galaxias que MaNGA.

−2.2 h
Ahorro de tiempo
horas/mes de asesores (MXN 673/mes)

2.1 veces
Productividad de la revisión
errores grandes hallados por hora de revisión

−56 %
Reducción de errores
masa vs. Katachi; SFR −17 %; D4000 −32 %

15.5 millones
Capacidad de procesamiento
galaxias/mes por GPU A100

Cálculo y supuestos en el Anexo A.

Mejora en la toma de decisiones. Ayuda a elegir qué galaxias observar y a comparar grupos.

Mejora en la calidad. Cada estimación indica su confiabilidad y puede reproducirse.

Facilidad o simplificación del trabajo. Solo requiere la imagen y la distancia de cada galaxia.

Innovación o diferenciación competitiva. El IA-UNAM adopta redes de visión reutilizables.

Elegimos la opción más austera: un solo lote, sin guardar imágenes y con alertas automáticas. El costo total de propiedad (TCO) a 12 meses suma MXN 167,885, con MXN 8,017 para imprevistos; como el desarrollo ya se realizó, el gasto nuevo es de MXN 88,183 (Anexo B).

$79,703
Desarrollo
MXN, ya realizado

$35,927
Implementación
MXN, meses 1 a 3

$44,240
Operación
MXN, meses 4 a 12

$167,885
TCO 12 meses
MXN, con imprevistos

El personal representa 84 % del costo y el cómputo 11 %: procesar una galaxia cuesta MXN 0.003 de GPU, y después del lote el mantenimiento cuesta MXN 2,326 al mes. Elegimos el modelo por su costo y beneficio, no solo por su precisión (Baccarin, 2020): una versión ligera con una sola red (ConvNeXt) es casi igual de precisa (error conjunto de 0.1120 frente a 0.1102) y usa 7.8 veces menos cómputo, pero en todo el lote ahorraría unos MXN 2,800, y no conviene cambiar de modelo. Como un modelo pierde confiabilidad si cambian sus datos o su uso (Babic et al., 2021), la Tabla 1 resume cómo detectar y reducir los riesgos.

Tabla 1: Riesgos principales y mitigación propuesta.

Riesgo	Mitigación
Modelo: en galaxias que casi no forman estrellas, la SFR estimada suele quedar alta.	Publicar la SFR con su indicador de confiabilidad, usarla para grupos de galaxias y revisar primero donde las redes discrepan. Alerta: error de SFR mayor que 0.65 dex.
Datos: galaxias o imágenes distintas a las de entrenamiento.	Marcar las galaxias fuera del rango aprendido. Alertas: cambio de brillo o ruido (PSI mayor que 0.2), más de 1 % de imágenes rechazadas o el doble de discrepancia.
Cobertura: requiere la distancia medida con espectroscopía.	Usar solo catálogos con esa distancia; sin ella, el error de masa crece entre 0.106 y 0.123 dex.
Operación: cambios en el equipo o resultados que no se reproducen.	Guardar cada versión con datos de referencia, empaquetar el software y nombrar un responsable.

Fuente: elaboración propia con base en Minutti Pérez & Bustos Cruz (2026).

Transferencia y continuidad

Entregaríamos el código con sus pruebas, el modelo entrenado, predicciones de referencia para comprobar que da los mismos resultados en otro equipo y el plan de monitoreo; la implementación sumaría el software empaquetado y una guía de operación. Un técnico académico del IA-UNAM sería responsable del modelo, con revisión trimestral de alertas y desempeño, y los asesores aprobarían cada versión antes de usarla.

Recomendamos aprobar un piloto de tres meses, por MXN 39,519, con galaxias de DESI comparables con las de MaNGA. Pasaría a operación si reproduce las predicciones de referencia, si su error queda por debajo de 0.12 dex en masa, 0.65 dex en SFR y 0.08 en D4000 en galaxias medidas en toda su extensión por otros proyectos, si procesa un millón de galaxias en menos de 50 horas de GPU y si los asesores aceptan sus indicadores de confiabilidad; si no, el piloto indicará si basta con recalibrar o hay que reentrenar.

Declaración de uso de inteligencia artificial

Usamos Claude (Anthropic, 2026) y ChatGPT (OpenAI, 2026) para organizar el texto, programar los cálculos y dar formato. La responsabilidad final sobre el contenido recae en los autores.

Referencias

Alfonzo, J. P., Iyer, K. G., Akiyama, M., Bryan, G. L., Cooray, S., Ludwig, E., Mowla, L., Omori, K. C., Pacifici, C., Speagle, J. S., y Wu, J. F. (2024). Katachi: Decoding the imprints of past star formation on present-day morphology in galaxies with interpretable CNNs. *The Astrophysical Journal*, *967*(2), 152. https://doi.org/10.3847/1538-4357/ad3b95

Anthropic. (2026). *Claude (Opus 5.5)* [Modelo de lenguaje grande]. https://claude.ai

Babic, B., Cohen, I. G., Evgeniou, T., y Gerke, S. (2021). When machine learning goes off the rails. *Harvard Business Review*, *99*(1). https://hbr.org/2021/01/when-machine-learning-goes-off-the-rails

Baccarin, F. (2020, 28 de diciembre). *Machine learning that pays the bills: Choosing models in business contexts.* Towards Data Science. https://towardsdatascience.com/machine-learning-that-pays-the-bills-choosing-models-in-business-contexts-e9003fd434a1/

Li, N., Zou, H., Gou, J., Guo, W., Li, W., Song, H., Sui, J., Tan, X., Xiao, Y., y Zhang, J. (2026). *Physical properties of 6.7 million galaxies from the DESI Bright Galaxy Survey: Spectral fitting and systematic tests with mock spectra.* https://doi.org/10.48550/arXiv.2607.19162

Minutti Pérez, L. C., y Bustos Cruz, E. A. (2026). *Inferencia de propiedades físicas de galaxias a partir de imágenes multibanda: Aprendizaje multitarea, adaptación de modelos preentrenados y ensambles heterogéneos* (Producto de difusión, Proyecto Integrador). Instituto Tecnológico y de Estudios Superiores de Monterrey.

OpenAI. (2026). *ChatGPT* [Modelo de lenguaje grande]. https://chatgpt.com

Sánchez, S. F., Barrera-Ballesteros, J. K., Lacerda, E., Mejía-Narváez, A., Camps-Fariña, A., Bruzual, G., Espinosa-Ponce, C., Rodríguez-Puebla, A., Calette, A. R., Ibarra-Medel, H., Avila-Reese, V., Hernández-Toledo, H., Bershady, M. A., Cano-Díaz, M., y Munguía-Cordova, A. M. (2022). SDSS-IV MaNGA: pyPipe3D analysis release for 10,000 galaxies. *The Astrophysical Journal Supplement Series*, *262*(2), 36. https://doi.org/10.3847/1538-4365/ac7b8f

Anexo A. Cálculo de los beneficios y supuestos

El escenario procesa en un solo lote las galaxias de DESI comparables con MaNGA, en una GPU NVIDIA A100 rentada por hora en Google Cloud; las imágenes se descargan, se procesan y se borran por tandas. Cada imagen se procesa en ocho versiones giradas o reflejadas y se promedian las predicciones, como en la evaluación del modelo. Los precios en dólares se convierten a pesos con el tipo de cambio FIX de mediados de noviembre de 2026, y las horas de personal se valoran con el tabulador de sueldos académicos de la UNAM, porque la operación quedaría a cargo del IA-UNAM. La Tabla 2 reúne los parámetros; los marcados como supuesto se medirán durante el piloto.

Tabla 2: Parámetros y supuestos de los cálculos.

Parámetro	Valor	Fuente
Tipo de cambio	18.60 MXN por USD	Banco de México (2026), FIX del 9 y 10 de noviembre, redondeado
GPU A100 40 GB (máquina a2-highgpu-1g, región us-central1)	US$3.6734/h sin compromiso; MXN 68.32/h	Google Cloud (2026a)
Almacenamiento estándar regional	US$0.020 por GiB al mes; MXN 0.37	Google Cloud (2026b)
Cálculo de las nueve redes	2.95 h por millón de galaxias; 23.6 h con las ocho versiones	Minutti Pérez & Bustos Cruz (2026)
Lectura, preparación y escritura de datos	Duplican el tiempo de cálculo	Supuesto conservador
Tamaño de una imagen	1.08 MB (3 filtros de 300 × 300 píxeles)	Minutti Pérez & Bustos Cruz (2026)
Tamaño del lote	2 millones de galaxias	Supuesto: cerca de 30 % de las 6.7 millones de Li et al. (2026); a verificar
Revisión de los asesores	50 galaxias al mes, 5 min cada una	Supuesto
Tarifa de ciencia de datos	MXN 190/h	Técnico Académico Titular B: MXN 25,359.20 al mes (Universidad Nacional Autónoma de México, 2026)
Tarifa de infraestructura	MXN 169/h	Técnico Académico Titular A: MXN 22,541.48 al mes (Universidad Nacional Autónoma de México, 2026)
Tarifa de asesoría científica	MXN 307/h	Investigador Titular C: MXN 40,892.80 al mes (Universidad Nacional Autónoma de México, 2026)
Conversión de sueldo a tarifa por hora	173.2 h al mes; factor de 1.3 por prestaciones	Supuesto
Horas de desarrollo	2 integrantes, 15 h/semana, 11 semanas	Estimación del equipo
GPU de desarrollo	150 h de A100	Estimación; el entrenamiento final de las nueve redes tomó 109.6 min

Capacidad de procesamiento. Un millón de galaxias requiere $23.6 \times 2 = 47.2$ h de GPU, de modo que el lote de 2 millones toma 94.4 h, unos cuatro días. Una A100 disponible las 730 h del mes procesaría $730/47.2 \approx 15.5$ millones de galaxias. MaNGA observó 10,010 galaxias en seis

años (Abdurro'uf et al., 2022), así que el lote equivale a unas 200 veces esa muestra. El modelo no reemplaza esas observaciones: aprende de ellas y extiende sus estimaciones a otras galaxias.

Reducción de errores. Cada reducción frente a Katachi es $1 - \mathrm{RMSE}_{\mathrm{modelo}}/\mathrm{RMSE}_{\mathrm{Katachi}}$: $1 - 0.0969/0.222 = 56\,\%$, $1 - 0.5575/0.668 = 17\,\%$ y $1 - 0.0676/0.100 = 32\,\%$ (Minutti Pérez y Bustos Cruz, 2026). Katachi no usa la distancia, y añadirla redujo por sí sola el error de masa entre 0.106 y 0.123 dex, casi toda la diferencia de 0.125 dex. Además, 89.4 % de las galaxias de prueba tiene un error de masa menor que 0.15 dex, unas 1.8 millones de galaxias del lote (elaboración propia con las predicciones del proyecto).

Ahorro de tiempo y productividad. Suponemos que los asesores revisan 50 galaxias al mes, 5 min cada una (4.2 h). En prueba, 23.7 % de las galaxias tiene un error de SFR mayor que 0.5 dex; en el 10 % de galaxias donde las tres redes más discrepan, la proporción sube a 50.0 % (elaboración propia). Si los asesores eligen al azar, encontrarían unos 12 errores grandes; si eligen las galaxias con mayor discrepancia, unos 25: 2.1 veces más por hora. Para encontrar los mismos 12 errores bastarían unas 24 revisiones (2.0 h), con un ahorro de 2.2 h al mes, equivalentes a $2.2 \times 307 =$ MXN 673. Ese 10 % equivale a 92 galaxias de prueba, por lo que el piloto debe confirmar la proporción. Los beneficios en pesos son pequeños: el valor principal del proyecto está en obtener estimaciones que hoy no existen.

Anexo B. Costo total de propiedad por servicio

La Tabla 3 desglosa el costo y la Figura 1 lo resume por fase y rubro. El desarrollo realizado completa el costo, pero no forma parte del gasto nuevo que se solicita.

Tabla 3: Desglose del costo total de propiedad a 12 meses, en pesos mexicanos.

Fase	Concepto	Cantidad	Unitario	Total
Desarrollo	Ciencia de datos: 2 integrantes, 15 h/semana, 11 semanas	330 h	190.00	62,700
	Asesoría científica IA-UNAM: 2 asesores, 1 h/semana	22 h	307.00	6,754
	GPU A100 para experimentos y entrenamiento	150 h GPU	68.32	10,249
	Subtotal desarrollo			*79,703*
Implementación	Software empaquetado, procesamiento por lotes, alertas automáticas y pruebas	120 h	190.00	22,800
	Infraestructura: entorno de cómputo	40 h	169.00	6,760
	Aceptación científica del piloto	16 h	307.00	4,912
	GPU: piloto de 300 mil galaxias y pruebas	20.2 h GPU	68.32	1,380
	Búfer temporal de imágenes (1 mes)	200 GiB-mes	0.37	74
	Subtotal implementación			*35,927*
Operación	GPU: lote único de 2 millones de galaxias	94.4 h GPU	68.32	6,450
	Búfer temporal de imágenes (1 mes)	200 GiB-mes	0.37	74
	Ciencia de datos: lote, catálogo y mantenimiento (24 h + 4 h/mes)	56 h	190.00	10,640
	Infraestructura: lote y mantenimiento (8 h + 2 h/mes)	24 h	169.00	4,056
	Asesores: aceptación del catálogo y revisión de 50 galaxias/mes (8 h + 4 h/mes)	40 h	307.00	12,280
	Revalidación anual: ciencia de datos	40 h	190.00	7,600
	Revalidación anual: asesoría científica	8 h	307.00	2,456
	GPU para revalidación	10 h GPU	68.32	683
	Subtotal operación			*44,240*
Imprevistos	10 % de implementación y operación			8,017
	Total a 12 meses			**167,885**
	Gasto nuevo (sin desarrollo realizado)			88,183

Fuente: elaboración propia con los supuestos de la Tabla 2.

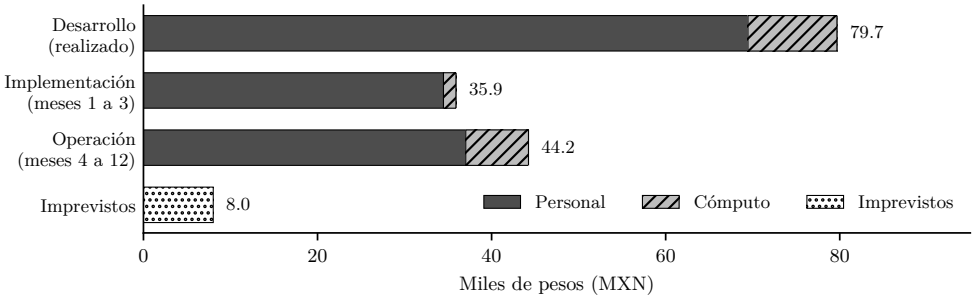


Figura 1: Costo total de propiedad a 12 meses por fase y rubro, en miles de pesos. Elaboración propia.

El costo depende sobre todo de las horas de personal. Valorar las horas de ciencia de datos 30 % por encima del tabulador sumaría MXN 31,122 (19 %), mientras que duplicar el precio de la GPU elevaría el TCO en MXN 18,762 (11 %) y un lote del doble de tamaño, en MXN 6,450 (4 %). Si el IA-UNAM dispone de GPU propias, el cómputo nuevo, MXN 8,661, desaparece del gasto.

Fuentes de los anexos

Abdurro'uf, Accetta, K., Aerts, C., Silva Aguirre, V., Ahumada, R., Ajgaonkar, N., Filiz Ak, N., Alam, S., Allende Prieto, C., Almeida, A., Anders, F., Anderson, S. F., Andrews, B. H., Anguiano, B., Aquino-Ortíz, E., Aragón-Salamanca, A., Argudo-Fernández, M., Ata, M., Aubert, M., ... y Zhu, K. (2022). The seventeenth data release of the Sloan Digital Sky Surveys: Complete release of MaNGA, MaStar, and APOGEE-2 data. *The Astrophysical Journal Supplement Series*, *259*(2), 35. https://doi.org/10.3847/1538-4365/ac4414

Banco de México. (2026). *Tipo de cambio FIX*. Consultado el 10 de noviembre de 2026, desde https://www.banxico.org.mx/tipcamb/tipCamMIAction.do

Google Cloud. (2026a). *Accelerator-optimized VM pricing*. Consultado el 10 de noviembre de 2026, desde https://cloud.google.com/products/compute/pricing/accelerator-optimized

Google Cloud. (2026b). *Cloud Storage pricing*. Consultado el 10 de noviembre de 2026, desde https://cloud.google.com/storage/pricing

Li, N., Zou, H., Gou, J., Guo, W., Li, W., Song, H., Sui, J., Tan, X., Xiao, Y., y Zhang, J. (2026). *Physical properties of 6.7 million galaxies from the DESI Bright Galaxy Survey: Spectral fitting and systematic tests with mock spectra*. https://doi.org/10.48550/arXiv.2607.19162

Minutti Pérez, L. C., y Bustos Cruz, E. A. (2026). *Inferencia de propiedades físicas de galaxias a partir de imágenes multibanda: Aprendizaje multitarea, adaptación de modelos preentrenados y ensambles heterogéneos* (Producto de difusión, Proyecto Integrador). Instituto Tecnológico y de Estudios Superiores de Monterrey.

Universidad Nacional Autónoma de México. (2026). *Tabulador de sueldos del personal académico, febrero de 2026*. Plataforma de Transparencia UNAM. https://www.plataformatransparencia.unam.mx/archivos/repositorio/SADM/2026/tabfeb2026/tabacafeb2026.pdf