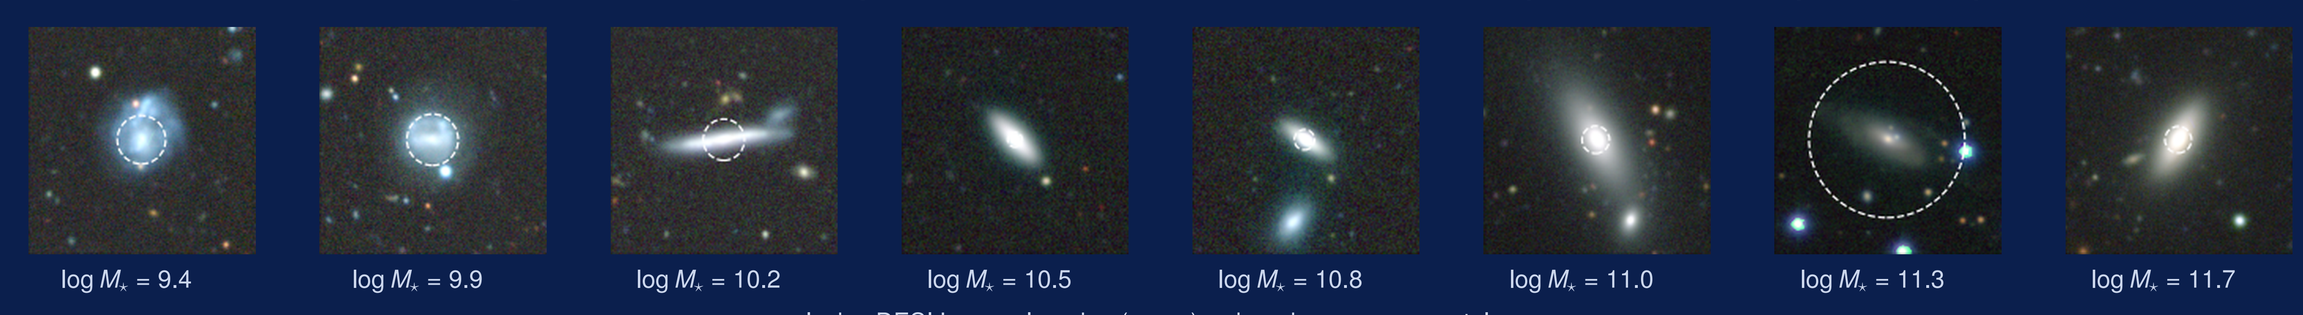
Inferencia de propiedades físicas de galaxias a partir de imágenes multibanda

Aprendizaje multitarea, adaptación de modelos preentrenados y ensambles heterogéneos

Luz Copelia Minutti Pérez · **Erick Alberto Bustos Cruz**
Maestría en Inteligencia Artificial Aplicada · Proyecto Integrador · Equipo 24
Asesores: Dr. Iván Reyes Amezcua (Tec) · Dr. Héctor Hernández Toledo y Dr. José A. Vázquez Mata (Instituto de Astronomía, UNAM)

Con **una imagen en tres filtros** y el **redshift** estimamos **masa**, **SFR** y **D4000** sin espectroscopía.



0.097 dex
Error en masa
≈25 % · meta: < 0.15 dex

0.068
Error en D4000
–32 % frente a Katachi

0.558 dex
Error en SFR
la propiedad más difícil

–37 %
Error conjunto
frente a la línea base inicial

RMSE en 917 galaxias de prueba, evaluadas una sola vez después de elegir el modelo.

El problema

Masa, SFR y D4000 se miden con espectroscopía, lenta y costosa; las imágenes llegan por millones.



Objetivo: valores de *galaxia completa*, comparables con MaNGA, a partir de la imagen.

Datos



g, r, z + z → log $M_\star$, log SFR, D4000

redshift

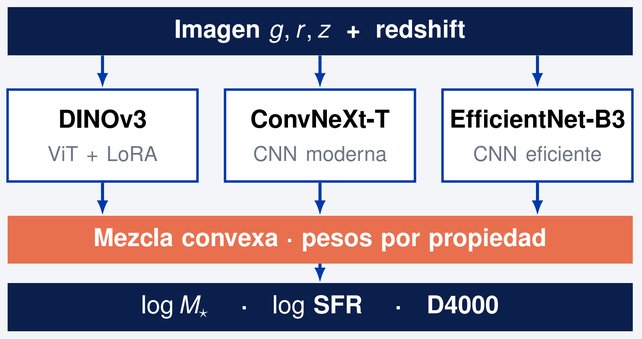
9,299 galaxias MaNGA · etiquetas Pipe3D

7,121 entrenamiento · **1,261** validación · **917** prueba

Método · CRISP-ML(Q)

1. **Datos** — calidad, recorte y escala global
2. **Líneas base** — fotométrica y Katachi en DESI
3. **Candidatos** — 6 modelos, ablaciones, Optuna
4. **Ensambles** — semillas y arquitecturas
5. **Prueba única** — modelo elegido antes de verla

Modelo: ensamble de tres redes

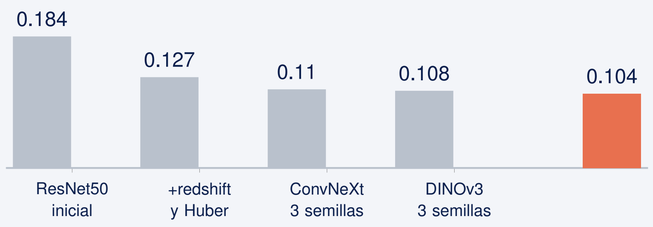


Cada red: 3 semillas y 8 giros o reflejos promediados.

	Masa	SFR	D4000
DINOv3	0.28	0.49	0.39
ConvNeXt	0.36	0.35	0.31
EfficientNet	0.36	0.16	0.30

Pesos de la mezcla: DINOv3 domina SFR y D4000; las CNN, la masa.

¿Qué hizo la diferencia?



Error conjunto en validación (menor es mejor).

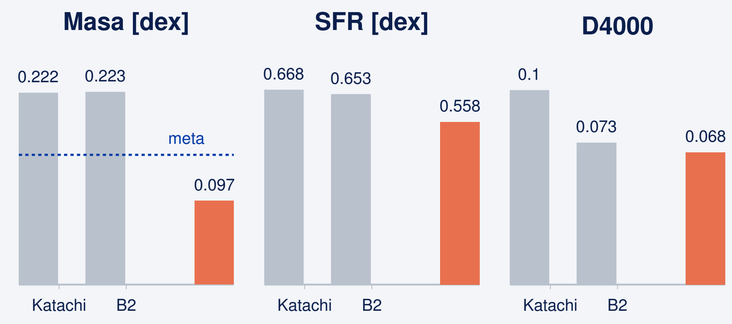
0.55 correlación brillo–masa con escala global por banda (0.02 por imagen)

÷2 error de masa al añadir el redshift

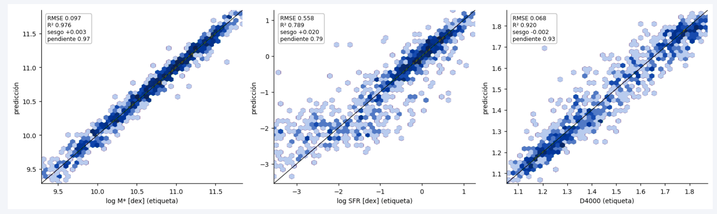
1.7 % de parámetros ajustados con LoRA bastan para adaptar DINOv3

–9 % error del ensamble frente a la mejor red sola (IC 95 % sin cero)

Resultados en prueba



RMSE frente a Katachi (Alfonzo et al., 2024) y su reproducción con imágenes DESI (B2).



Predicción frente a valor medido. R^2: 0.98 en masa, 0.79 en SFR y 0.92 en D4000.

Límites y señal de confianza

En galaxias que casi no forman estrellas, la **SFR estimada queda alta**. Cuando las tres redes **discrepan**, el error suele ser mayor.

Revisar al azar — **23.7 %**

Revisar el 10 % con más desacuerdo — **50.0 %**

galaxias con error de SFR mayor que 0.5 dex

2.1× más errores grandes encontrados por hora de revisión.

Valor para el IA-UNAM, costo y transferencia

Capacidad

2 M galaxias DESI comparables (estimado)

4 días con una GPU A100

200× más galaxias que MaNGA

Catálogo versionado: tres propiedades, **indicador de confiabilidad** y versión del modelo por galaxia.

Costo total a 12 meses

$167,885 costo total, MXN

$88,183 gasto nuevo, MXN



miles de MXN · desarrollo (realizado), implementación, operación e imprevistos

84 % es personal; una galaxia cuesta MXN 0.003 de GPU.

Transferencia y continuidad

Piloto de 3 meses (MXN 39,519) con galaxias de DESI. Pasa a operación si reproduce las predicciones de referencia, mantiene el error bajo 0.12 / 0.65 / 0.08, procesa un millón de galaxias en menos de 50 h de GPU y los asesores aceptan la confiabilidad.

Se entrega código con pruebas, modelo, predicciones de referencia, guía de operación y alertas de cambio en los datos.

Responsable: un técnico académico del IA-UNAM, con revisión trimestral.

Conservar el brillo, sumar la distancia, adaptar redes preentrenadas y combinarlas permite **extender las mediciones de MaNGA a millones de galaxias**, con un error y una confiabilidad conocidos.

Referencias. Alfonzo, J. P. et al. (2024). Katachi. *ApJ*, 967(2), 152. · Sánchez, S. F. et al. (2022). SDSS-IV MaNGA: pyPipe3D. *ApJS*, 262(2), 36. · Li, N. et al. (2026). Physical properties of 6.7 million galaxies from DESI BGS. arXiv:2607.19162. · Ivezić, Ž. et al. (2019). LSST. *ApJ*, 873(2), 111. · Dey, A. et al. (2019). DESI Legacy Imaging Surveys. *AJ*, 157(5), 168. · Siméoni, O. et al. (2025). DINOv3. arXiv:2508.10104. · Hu, E. J. et al. (2022). LoRA. *ICLR*. · Studer, S. et al. (2021). CRISP-ML(Q). *MAKE*, 3(2), 392–413. · Minutti Pérez, L. C. y Bustos Cruz, E. A. (2026). Producto de difusión, Proyecto Integrador, Tecnológico de Monterrey.

Declaración de uso de IA. Anthropic. (2026). Claude (Opus 5.5) [Modelo de lenguaje grande], utilizado para la síntesis del contenido, el diseño y el formato del póster en LaTeX a partir del artículo y el resumen ejecutivo del equipo. https://claude.ai. La responsabilidad final sobre el contenido recae en los autores.